



Análise descritiva das Ordens de Manutenção em uma Indústria Farmacêutica

Aluna: Larissa Mitrof de Lima

E-mail: larissa.mitrof@gmail.com

GitHub: <https://github.com/>

Discord: larissamitrof

Sprint: Engenharia de Dados (40530010057_20260_01)

SUMÁRIO

Análise descritiva das Ordens de Manutenção em uma Indústria Farmacêutica	1
Contextualização e Objetivos Gerais	3
Dados brutos: contexto e estrutura	4
Licença e uso de dados	4
Carga dos Dados	4
Modelagem e Catálogo de Dados.....	6
Catálogo de Dados	7
Catálogo de Dados Transcrito	8
Pipeline de Dados.....	12
Organização do ETL	12
Transformações Realizadas (Silver).....	13
Evidências de persistência e validação	13
Qualidade de Dados	15
Problemas detectados e como foram resolvidos.....	15
Evidências: Completude	16
Evidências: Consistência	17
Evidências: Unicidade	19
Evidências: Acurácia.....	20
Evidências: Acurácia.....	23
Análise de Dados	23
Considerações Finais	30

Contextualização e Objetivos Gerais

A análise de dados provenientes das ordens de manutenção em uma indústria farmacêutica é fundamental para garantir a confiabilidade e segurança dos equipamentos, o cumprimento das diretrizes regulatórias e a continuidade dos processos produtivos. Extraídos do ERP TOTVS Datasul no período de 01/01/2026 a 31/08/2026, os dados utilizados oferecem uma visão estruturada sobre a realização e/ou planejamento das manutenções, permitindo avaliar os dados através dos tipos de manutenção realizadas (preventiva, corretiva, emergencial), status, localização e equipamentos envolvidos.

Problema a resolver - Construir um pipeline de dados na nuvem que transforme a exportação bruta de ordens de manutenção em um modelo organizado, documentado e de qualidade verificada para responder a cinco perguntas centrais:

- 1 - Carga de trabalho:** qual é a composição das OMs por grupo de manutenção (preventiva/inspeção, corretiva, projetos/melhorias, apoio) e por mês? Qual a proporção entre preventivas e corretivas?
- 2 - Equipamentos problemáticos:** quais classes de equipamento concentram mais OMs corretivas (planejadas e emergenciais)?
- 3 - Conclusão e backlog:** qual a taxa de conclusão das OMs por grupo e por tipo de manutenção? Onde se concentram as OMs suspensas e não iniciadas?
- 4 - Tempo de execução:** quanto tempo (mediana e média, em dias) as manutenções levam, por grupo e por tipo?
- 5 - Evolução mensal:** como evoluíram, de janeiro a agosto, o volume de OMs, a taxa de conclusão e as corretivas emergenciais?

Dessa forma, o pipeline não apenas permitirá identificar padrões de falhas, avaliar a eficiência das ações de manutenção e antecipar necessidades críticas, mas também garantirá maior segurança operacional e otimização de recursos em um setor altamente regulado e sensível como o farmacêutico.

Os principais objetivos desse pipeline incluem:

- **Organizar e padronizar os dados** extraídos do ERP, garantindo consistência e qualidade da informação.
- **Automatizar o fluxo de análise**, reduzindo o tempo entre a coleta e a geração de insights.
- **Suportar decisões estratégicas**, permitindo priorização de recursos e planejamento de manutenções preventivas.
- **Gerar relatórios e visualizações dinâmicas**, facilitando a comunicação entre áreas técnicas e gerenciais.

Dados brutos: contexto e estrutura

O arquivo [om_manutencao_2026.csv](#) (2,83 MB, codificação UTF-8, separador vírgula) contém **25.872 linhas** e **10 colunas**. Cada linha é uma ordem de manutenção; não há tabelas relacionadas, o arquivo é uma tabela única.

Tabela 1 – Descrição dos dados das colunas

Coluna	Descrição	Exemplo
linha	Número sequencial da linha no arquivo	1
ordem	Número da OM (9 dígitos, único)	300144284
equipamento	Código do equipamento (letras da classe + número)	AUT114
nome_equipamento	Descrição do equipamento	AUTOCLAVE
tag	Código técnico/local (formato 9.999.9.9999)	1.023.3.0346
tipo_manutencao	Tipo da OM (16 valores)	PREVENTIVA
data_manutencao	Data da manutenção registrada (texto dd/MM/yyyy)	28/04/2026
data_termino	Data de término (vazia se não terminada)	01/07/2026
data_inicio_original	Data de início originalmente prevista	26/06/2026
estado_om	Terminada, Suspensa, Não Iniciada ou Iniciada	Terminada

Licença e uso de dados

Origem: exportação de relatório do sistema ERP TOTVS Data Sul, tela MI0629. Dados reais internos.

Licença: não se trata de dado aberto e não possui licença pública. O uso é exclusivamente acadêmico deste trabalho na PUC-Rio para posterior aplicação na empresa, mediante autorização da chefia.

Dados pessoais: colunas que pudessem apresentar dados sigilosos foram excluídas na fase de extração dos dados. A base não contém nomes de pessoas ou siglas de departamentos, CPF, matrícula, e-mails ou quaisquer outros dados pessoais ou capazes de caracterizar a instituição. As colunas de ordem, equipamentos, tags, tipos ou datas são colunas identificadoras. Por isso não foi necessária anonimização.

Publicação: o arquivo de dados não foi publicado no repositório por se tratar de dados institucionais.

Carga dos Dados

Coleta e upload: Os dados foram exportados do sistema ERP TOTVS Data Sul em formato CSV e enviado ao Databricks pela interface (Catalog > workspace > bronze > raw_files > Upload to this volume).

Caminho final: /Volumes/workspace/bronze/raw_files/om_manutencao_2026.csv.

Ingestão para tabela: A tabela Delta é gravada (workspace.bronze.om_manutencao_raw), sem alteração de nenhum valor. Todas as colunas entram como texto (inferColumnTypes => false), para preservar exatamente o que veio da fonte, inclusive erros. São adicionadas duas colunas de controle: _arquivo_origem e _ingerido_em, que dão rastreabilidade.

MVP - Data Engineering

Pipeline de Dados na Nuvem




Figura 01 - Volume raw_files no Unity Catalog - arquivo om_manutencao_2026.csv (2,83 MB) carregado.




Figura 02 – Total de linhas Catalog - arquivo om_manutencao_2026.csv (2,83 MB) carregado.




Figura 03 – Tipos das colunas no Catalog - arquivo om_manutencao_2026.csv (2,83 MB) carregado.

Modelagem e Catálogo de Dados

O modelo escolhido foi do tipo esquema estrela devido ao objetivo de analisar eventos (Ordens de Manutenção) sob diferentes perspectivas (equipamentos, tipo de manutenção, tempo), permitindo que as consultas sejam simples e rápidas e refletindo diretamente as perguntas de negócio.




Figura 04 – Esquema escolhido para camada Gold.

Tabela 2 – Descrição das tabelas fato e dimensão utilizadas

Tabela	Tipo	Granularidade (1 linha = ...)	Linhas	Para que serve
fato_ordem_manutencao	Fato	1 ordem de manutenção	25.872	Estado, datas, duração e sinalizadores de qualidade de cada OM
dim_equipamento	Dimensão	1 código de equipamento	7.221	Nome e classe do equipamento (ex.: AUT = autoclave)
dim_tipo_manutencao	Dimensão	1 tipo de manutenção	16	Agrupar os tipos em 4 grupos de negócio
dim_data	Dimensão	1 dia (2026 e 2027)	730	Ano, mês, trimestre e dia da semana

Decisões de modelagem

- A coluna tag fica na fato, pois não se trata de uma dimensão, o código reflete a localização, prédio, sala onde o equipamento está localizado: no diagnóstico, 181 equipamentos apareceram associados a mais de uma tag.
- Classe do equipamento: as letras iniciais do código (AUT, CHI, ARS...) formam 225 classes; o nome da classe representa o tipo equipamento mais frequente dentro dela.
- Grupos de manutenção: os 16 tipos foram agrupados em Preventiva/Inspeção, Corretiva, Projetos/Melhorias e Apoio/Administrativo. Foi a decisão de negócio documentada na tabela dim_tipo_manutencao.
- Data de referência: as análises mensais usam data_inicio_original, representando a data de quando a Ordem de manutenção foi gerada no sistema.
- Chaves naturais (código do equipamento, número da OM) em vez de chaves artificiais, foram utilizadas para simplificar o trabalho.

MVP - Data Engineering

Pipeline de Dados na Nuvem




Figura 05 – Árvore Catalog – camadas bronze, silver e gold.

Catálogo de Dados

O catálogo foi registrado no Unity Catalog (comentários de tabela e de coluna gravados pelo notebook 05, com tipo e linhagem exibidos automaticamente pelo Databricks) e transcrito abaixo. Para cada tabela: descrição, e para cada coluna: descrição, tipo, domínio de valores e linhagem.

fato_ordem_manutencao						
Overview						
Description						
Fato: 1 linha por ordem de manutenção (OM), jan-ago/2026.						
Column	Type	Popularity	Comment	Tags	Column masking	
ordem	bigint	...				
cod_equipamento	string	...				
tipo_manutencao	string	...				
data_inicio_original	date	...				
tag_local	string	...				
estado_om	string	...				
data_manutencao	date	...				
data_termino	date	...				
duracao_dias	int	...				
flag_ano_corrigido	boolean	...				
flag_termino_antes_inicio	boolean	...				
flag_manutencao_fora_2026	boolean	...				
flag_tag_ausente	boolean	...				

Figura 6 – Catálogo de Dados- tabela fato




Figura 7 – Linhagem da tabela fato

Catálogo de Dados Transcrito

workspace.bronze.om_manutencao_raw (Bronze)

Ordens de manutenção (OM) de janeiro a agosto de 2026, exatamente como exportadas do sistema de gestão de manutenção. Nenhum valor foi alterado; todas as colunas originais estão em texto. Granularidade: 1 linha por OM (25.872 linhas). Origem: arquivo om_manutencao_2026.csv, carregado no volume workspace.bronze.raw_files.

Tabela 3 – Descrição dos tipos de dados da camada bronze

Coluna	Tipo	Descrição	Domínio	Linhagem
linha	STRING	Número sequencial da linha no arquivo exportado.	Texto numérico de 1 a 25872.	CSV: coluna linha (sem transformação).
ordem	STRING	Número da ordem de manutenção (OM), identificador único da OM.	Texto numérico de 9 dígitos (100050417 a 300157661).	CSV: coluna ordem (sem transformação).
equipamento	STRING	Código do equipamento: letras da classe + número (ex.: AUT114 = autoclave 114). O código PREDIAL representa manutenção predial geral, sem equipamento específico.	Texto de 4 a 16 caracteres; pode ter minúsculas (problema tratado na Silver).	CSV: coluna equipamento (sem transformação).
nome_equipamento	STRING	Descrição textual do equipamento (ex.: AUTOCLAVE, CHILLER).	656 nomes distintos.	CSV: coluna nome_equipamento (sem transformação).
tag	STRING	Tag: código de identificação técnica/local do ativo, no formato 9.999.9.9999 (ex.: 1.023.3.0346).	Texto de 12 a 13 caracteres; 7 valores vazios.	CSV: coluna tag (sem transformação).
tipo_manutencao	STRING	Tipo da ordem de manutenção (ex.: PREVENTIVA, INSPEÇÃO, CORRETIVA PLANEJADA).	16 categorias (ver dim_tipo_manutencao).	CSV: coluna tipo_manutencao (sem transformação).

MVP - Data Engineering

Pipeline de Dados na Nuvem

data_manutencao	STRING	Data da manutenção registrada na OM, em texto dd/MM/yyyy. Em 74% das OMs fica a até 7 dias do início original.	Datas de 2022 a 2027 (a maioria em 2026); contém o valor inválido 28/04/0026.	CSV: coluna data_manutencao (sem transformação).
data_termino	STRING	Data de término (encerramento) da OM, em texto dd/MM/yyyy. Vazia quando a OM não foi terminada.	Vazia em 1.965 linhas (todas OMs não terminadas).	CSV: coluna data_termino (sem transformação).
data_inicio_original	STRING	Data de início originalmente prevista da OM, em texto dd/MM/yyyy.	01/01/2026 a 31/08/2026.	CSV: coluna data_inicio_original (sem transformação).
estado_om	STRING	Situação atual da OM.	Terminada, Suspensa, Não Iniciada, Iniciada.	CSV: coluna estado_om (sem transformação).
_rescued_data	STRING	Coluna criada automaticamente pelo Databricks: guarda dados que não couberam no formato esperado na leitura do CSV.	Esperado: sempre vazia (NULL).	Gerada pelo read_files.
_arquivo_origem	STRING	Metadado de controle: caminho do arquivo do qual a linha foi lida.	/Volumes/workspace/bronze/raw_files/om_manutencao_2026.csv	Metadado _metadata.file_path.
_ingerido_em	TIMESTAMP	Metadado de controle: data e hora da carga na Bronze.	Data/hora da execução do notebook 01.	current_timestamp() no notebook 01.

workspace.silver.om_manutencao (Silver)

Ordens de manutenção limpas: tipos corretos (datas como DATE), textos padronizados em maiúsculas, erro de ano corrigido e problemas de qualidade sinalizados em colunas flag_*. Granularidade: 1 linha por OM (25.872 linhas). Origem: workspace.bronze.om_manutencao_raw (notebook 03).

Tabela 4 – Descrição dos tipos de dados da camada silver

Coluna	Tipo	Descrição	Domínio	Linhagem
linha_origem	INT	Número da linha no arquivo original (rastreadibilidade).	1 a 25872.	bronze.om_manutencao_raw.linha via try_cast INT (T1).
ordem	BIGINT	Número da ordem de manutenção (OM). Chave primária: única em toda a tabela.	100050417 a 300157661; sem duplicatas.	bronze.om_manutencao_raw.ordem via try_cast BIGINT (T1).
equipamento	STRING	Código do equipamento em maiúsculas (ex.: AUT114). PREDIAL = manutenção predial geral.	7.221 códigos distintos.	bronze.om_manutencao_raw.equipamento com UPPER(TRIM) (T2).
nome_equipamento	STRING	Descrição do equipamento em maiúsculas.	656 nomes distintos.	bronze.om_manutencao_raw.nome_equipamento com UPPER(TRIM) (T2).
tag	STRING	Tag (código técnico/local) em maiúsculas. NULL quando ausente.	1.585 tags distintas; 7 NULL.	bronze.om_manutencao_raw.tag com UPPER(TRIM), vazios viram NULL (T2, T3).
tipo_manutencao	STRING	Tipo da OM em maiúsculas.	16 categorias.	bronze.om_manutencao_raw.tipo_manutencao com UPPER(TRIM) (T2).

MVP - Data Engineering

Pipeline de Dados na Nuvem

estado_om	STRING	Situação da OM em maiúsculas.	TERMINADA, SUSPENSÃO, NÃO INICIADA, INICIADA.	bronze.om_manutencao_raw.estado_om com UPPER(TRIM) (T2).
data_manutencao	DATE	Data da manutenção registrada na OM.	2022-11-28 a 2027-08-23 (461 fora de 2026 sinalizadas).	bronze.om_manutencao_raw.data_manutencao: correção do ano 00xx e conversão dd/MM/yyyy para DATE (T4, T5).
data_termino	DATE	Data de término da OM. NULL quando a OM não foi terminada.	2023-03-15 a 2026-09-04; 1.965 NULL (OMs não terminadas).	bronze.om_manutencao_raw.data_termino: correção do ano e conversão para DATE (T4, T5).
data_inicio_original	DATE	Data de início originalmente prevista da OM. É a data de referência das análises.	2026-01-01 a 2026-08-31.	bronze.om_manutencao_raw.data_inicio_original: conversão para DATE (T5).
duracao_dias	INT	Dias entre início original e término. Calculada só para OM TERMINADA com datas coerentes; caso contrário NULL.	0 a 217; 23.238 preenchidas.	datediff(data_termino, data_inicio_original) (T7).
classe Equipamento	STRING	Classe do equipamento: letras iniciais do código (AUT, CHI, ARS...).	225 classes.	regexp_extract(equipamento, letras iniciais) (T8).
mes_referencia	DATE	Primeiro dia do mês do início original.	2026-01-01 a 2026-08-01 (8 meses).	trunc(data_inicio_original, MM) (T9).
flag_ano_corrigido	BOOLEAN	Verdadeiro se alguma data teve o ano inválido (00xx) corrigido para 20xx.	true em 1 linha.	Comparação regex sobre datas da Bronze (T4/T6).
flag_termino_antes_inicio	BOOLEAN	Verdadeiro se data_termino é anterior a data_inicio_original (inconsistência). Essas OMs ficam sem duracao_dias.	true em 669 linhas.	data_termino < data_inicio_original (T6).

workspace.gold.dim_equipamento (Gold)

Dimensão de equipamentos do esquema estrela. Granularidade: 1 linha por código de equipamento (7.221 linhas). Origem: workspace.silver.om_manutencao (notebook 04).

Tabela 5 – Descrição dos tipos de dados da tabela dimensão equipamentos na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
cod_equipamento	STRING	Código do equipamento (chave da dimensão).	7.221 valores únicos.	silver.om_manutencao.equipamento.
nome_equipamento	STRING	Descrição do equipamento.	656 nomes distintos.	silver.om_manutencao.nome_equipamento (MAX por código).
classe_equipamento	STRING	Classe do equipamento (letras iniciais do código).	225 classes.	silver.om_manutencao.classe_equipamento.
nome_classe	STRING	Nome legível da classe: o nome de equipamento mais frequente dentro da classe (ex.: AUT = AUTOCLAVE).	225 valores.	Calculado com ROW_NUMBER sobre a frequência de nomes por classe.

MVP - Data Engineering

Pipeline de Dados na Nuvem

workspace.gold.dim_tipo_manutencao (Gold)

Dimensão de tipos de manutenção com agrupamento de negócio. Granularidade: 1 linha por tipo (16 linhas). Origem: tabela de mapeamento definida no notebook 04.

Tabela 6 – Descrição dos tipos de dados da tabela dimensão tipo de manutenção na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
tipo_manutencao	STRING	Tipo da ordem de manutenção (chave da dimensão).	16 valores únicos.	silver.om_manutencao.tipo_manutencao.
grupo_manutencao	STRING	Grupo de negócio do tipo: PREVENTIVA/INSPEÇÃO, CORRETIVA, PROJETOS/MELHORIAS ou APOIO/ADMINISTRATIVO.	4 grupos.	Mapeamento manual definido no notebook 04 (decisão de modelagem).

workspace.gold.dim_data (Gold)

Dimensão calendário. Granularidade: 1 linha por dia, de 01/01/2026 a 31/12/2027 (730 linhas). Gerada por código, sem fonte externa.

Tabela 7 – Descrição dos tipos de dados da tabela dimensão data na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
data	DATE	Dia do calendário (chave da dimensão).	2026-01-01 a 2027-12-31.	sequence() no notebook 04.
ano	INT	Ano.	2026 ou 2027.	year(data).
mes	INT	Número do mês.	1 a 12.	month(data).
nome_mes	STRING	Nome do mês em português.	Janeiro a Dezembro.	Derivado de month(data).
ano_mes	STRING	Ano e mês no formato yyyy-MM (útil para ordenar gráficos).	2026-01 a 2027-12.	date_format(data, yyyy-MM).
trimestre	INT	Trimestre do ano.	1 a 4.	quarter(data).
dia_semana	STRING	Nome do dia da semana em português.	Domingo a Sábado.	Derivado de dayofweek(data).

workspace.gold.fato_ordem_manutencao (Gold)

Tabela fato do esquema estrela. Granularidade: 1 linha por ordem de manutenção (25.872 linhas). Relaciona-se com dim Equipamento (cod_equipamento), dim_tipo_manutencao (tipo_manutencao) e dim_data (data_inicio_original). Origem: workspace.silver.om_manutencao (notebook 04).

Tabela 8 – Descrição dos tipos de dados da tabela fato na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
ordem	BIGINT	Número da OM (chave da fato).	Único; 100050417 a 300157661.	silver.om_manutencao.ordem.
cod_equipamento	STRING	Chave estrangeira para dim_equipamento.	7.221 valores.	silver.om_manutencao.equipamento.
tipo_manutencao	STRING	Chave estrangeira para dim_tipo_manutencao.	16 valores.	silver.om_manutencao.tipo_manutencao.
data_inicio_original	DATE	Chave estrangeira para dim_data; data de referência das análises.	2026-01-01 a 2026-08-31.	silver.om_manutencao.data_inicio_original.

MVP - Data Engineering

Pipeline de Dados na Nuvem

tag_local	STRING	Tag (código técnico/local) da OM. Fica na fato porque um equipamento pode ter mais de uma tag.	1.585 tags; 7 NULL.	silver.om_manutencao.tag.
estado_om	STRING	Situação da OM.	TERMINADA, SUSPensa, NÃO INICIADA, INICIADA.	silver.om_manutencao.estado_om.
data_manutencao	DATE	Data da manutenção registrada na OM.	2022-11-28 a 2027-08-23.	silver.om_manutencao.data_manutencao.
data_termino	DATE	Data de término da OM; NULL se não terminada.	2023-03-15 a 2026-09-04.	silver.om_manutencao.data_termino.
duracao_dias	INT	Medida: dias de execução (término - início original). NULL se não aplicável.	0 a 217.	silver.om_manutencao.duracao_dias.
flag_ano_corrigido	BOOLEAN	Sinalizador: ano de data corrigido.	1 linha true.	silver.om_manutencao.flag_ano_corrigido.
flag_termino_antes_inicio	BOOLEAN	Sinalizador: término anterior ao início.	669 linhas true.	silver.om_manutencao.flag_termino_antes_inicio.
flag_manutencao_fora_2026	BOOLEAN	Sinalizador: data_manutencao fora de 2026.	461 linhas true.	silver.om_manutencao.flag_manutencao_fora_2026.
flag_tag_ausente	BOOLEAN	Sinalizador: OM sem tag.	7 linhas true.	silver.om_manutencao.flag_tag_ausente.

Pipeline de Dados

Organização do ETL

O pipeline segue a **Arquitetura Medalhão**: dado bruto (Bronze), dado limpo (Silver) e dado pronto para consumo (Gold). O processo foi **ramificado em notebooks separados** para facilitar a manutenção e organização fluxo de processo, todos em SQL para execução em sequência na computação serverless do Databricks. Caso seja necessário a mudança da regra de limpeza, é possível alterar apenas o notebook 03 e a reexecução dos demais notebooks.

Tabela 9 – Descrição dos notebooks e organização das camadas

Fluxo	Notebook	O que faz	Tabela resultante
Extract + Load	01_bronze_ingestao	Lê o CSV do volume e grava sem alterar valores	bronze.om_manutencao_raw
Diagnóstico	02_qualidade_diagnostico	Mede problemas (não altera dados)	(consultas)
Transform	03_silver_limpeza	Tipagem, padronização, correções e sinalizações	silver.om_manutencao
Load (modelo)	04_gold_modelagem	Cria fato e dimensões (esquema estrela)	gold.fato_ordem_manutencao, dim Equipamento, dim_tipo_manutencao, dim_data
Documentação	05_catalogo_dados	Descrições de tabelas/colunas no Unity Catalog	(metadados)
Consumo	06_analise_perguntas	Responde às 5 perguntas de negócio	(consultas)

MVP - Data Engineering

Pipeline de Dados na Nuvem


Transformações Realizadas (Silver)

Tabela 10 – Descrição das transformações realizadas na camada silver

#	Transformação	Por que foi feita	Impacto nos dados
T1	Conversão de linha e ordem para número (try_cast)	Identificadores estavam como texto	Tipos INT e BIGINT
T2	UPPER(TRIM()) em textos	"predial" e "PREDIAL" eram contados como equipamentos diferentes	7.608 para 7.221 códigos de equipamento
T3	Texto vazio vira NULL	Vazio e NULL significam "sem valor"	Ausência padronizada
T4	Correção do ano 00xx para 20xx	28/04/0026 é erro de digitação (início em 17/04/2026)	1 linha corrigida e sinalizada
T5	Conversão de texto dd/MM/yyyy para DATE	Permite cálculos e ordenação correta	3 colunas de data tipadas
T6	Colunas flag_* de qualidade	Problemas duvidosos são sinalizados, não apagados	669 / 461 / 7 / 1 linhas sinalizadas
T7	duracao_dias = término - início	Métrica da pergunta 4; só OM terminada e coerente	23.238 OMs com duração
T8	classe_equipamento (letras iniciais do código)	Agrupar equipamentos do mesmo tipo	225 classes
T9	mes_referencia (mês do início original)	Facilitar análises mensais	8 meses
T10	Deduplicação por ordem (QUALIFY ROW_NUMBER)	Garantir 1 linha por OM em cargas futuras	0 duplicatas removidas hoje

Reprodutibilidade: todas as tabelas são criadas com CREATE OR REPLACE TABLE, portanto reexecutar a sequência de notebooks com um arquivo novo refaz o pipeline sozinho, sem duplicar dados. Nenhuma linha foi excluída ao longo do pipeline: Bronze, Silver e a fato têm o mesmo total (25.872).

Evidências de persistência e validação



```

1 -- V1: nenhuma linha foi perdida entre Bronze e Silver (esperado: 25872 nas duas)
2 SELECT
3   (SELECT COUNT(*) FROM workspace.bronze.om_manutencao_raw) AS linhas_bronze,
4   (SELECT COUNT(*) FROM workspace.silver.om_manutencao) AS linhas_silver;

```


	linhas_bronze	linhas_silver
1	25872	25872

1 row · 6.087s runtime · Refreshed 48m ago

Figura 8 – Validação da Silver: mesma contagem da Bronze (V1)

MVP - Data Engineering

Pipeline de Dados na Nuvem




```

1 -- V4: contagem de cada sinalização de qualidade
2 SELECT
3   SUM(CASE WHEN flag_ano_corrigido THEN 1 ELSE 0 END) AS ano_corrigido, -- esperado 1
4   SUM(CASE WHEN flag_termino_antes_inicio THEN 1 ELSE 0 END) AS termino_antes_inicio, -- esperado 669
5   SUM(CASE WHEN flag_manutencao_fora_2026 THEN 1 ELSE 0 END) AS manutencao_fora_2026, -- esperado 461
6   SUM(CASE WHEN flag_tag_ausente THEN 1 ELSE 0 END) AS tag_ausente, -- esperado 7
7   SUM(CASE WHEN duracao_dias IS NOT NULL THEN 1 ELSE 0 END) AS oms_com_duracao -- esperado 23238
8 FROM workspace.silver.om_manutencao;

```

	ano_corrigido	termino_antes_inicio	manutencao_fora_2026	tag_ausente	oms_com_duracao
1	1	669	461	7	23237

Figura 9 - Contagem de sinalizações de qualidade (V4).



```

1 SELECT 'G1 - linhas Bronze' AS verificacao, COUNT(*) AS resultado FROM workspace.bronze.om_manutencao_raw
2 UNION ALL SELECT 'G1 - linhas Silver', COUNT(*) FROM workspace.silver.om_manutencao
3 UNION ALL SELECT 'G1 - linhas fato (Gold)', COUNT(*) FROM workspace.gold.fato_ordem_manutencao
4 UNION ALL SELECT 'G2 - OMs sem equipamento', COUNT(*) FROM workspace.gold.fato_ordem_manutencao f LEFT JOIN workspace.gold.dim_equipamento e ON f.
   cod_equipamento = e.cod_equipamento WHERE e.cod_equipamento IS NULL
5 UNION ALL SELECT 'G2 - OMs sem tipo', COUNT(*) FROM workspace.gold.fato_ordem_manutencao f LEFT JOIN workspace.gold.dim_tipo_manutencao t ON f.
   tipo_manutencao = t.tipo_manutencao WHERE t.tipo_manutencao IS NULL
6 UNION ALL SELECT 'G2 - OMs sem data', COUNT(*) FROM workspace.gold.fato_ordem_manutencao f LEFT JOIN workspace.gold.dim_data d ON f.
   data_inicio_original = d.data WHERE d.data IS NULL
7 UNION ALL SELECT 'G4 - linhas dim_equipamento', COUNT(*) FROM workspace.gold.dim_equipamento
8 UNION ALL SELECT 'G4 - linhas dim_tipo_manutencao', COUNT(*) FROM workspace.gold.dim_tipo_manutencao
9 UNION ALL SELECT 'G4 - linhas dim_data', COUNT(*) FROM workspace.gold.dim_data;

```

	verificacao	resultado
1	G2 - OMs sem equipamento	0
2	G2 - OMs sem tipo	0
3	G2 - OMs sem data	0
4	G1 - linhas Bronze	25872
5	G1 - linhas Silver	25872
6	G1 - linhas fato (Gold)	25872
7	G4 - linhas dim_equipamento	7221
8	G4 - linhas dim_tipo_manutenc...	16
9	G4 - linhas dim_data	730

Figura 10 - Validação da Gold: reconciliação de volumes (bronze = silver = fato = 25.872), integridade referencial e tamanho das tabelas.

Qualidade de Dados

A qualidade foi avaliada **para cada atributo** do conjunto de dados, na camada Bronze (notebook 02), considerando as cinco dimensões pedidas: completude, consistência, unicidade, acurácia e outliers. Os tratamentos foram aplicados na Silver (notebook 03) e verificados por consultas de validação. Onde o problema não pôde ser corrigido com certeza, o registro foi **mantido e sinalizado**, e não apagado.

Problemas detectados e como foram resolvidos

Tabela 11 – resumo dos problemas detectados e resolvidos na camada silver

#	Dimensão	Problema detectado	Qtd	Tratamento
1	Completude	data_termino vazia	1.965	Mantido como NULL: 100% são OMs não terminadas (Suspensa, Não Iniciada, Iniciada). Comportamento esperado, não é erro.
2	Completude	tag vazia	7	Mantido NULL + flag_tag_ausente
3	Consistência	Ano impossível (28/04/0026)	1 linha (2 campos)	Corrigido para 2026 + flag_ano_corrigido
4	Consistência	Datas armazenadas como texto	todas	Convertidas para DATE (formato dd/MM/yyyy validado: 0 fora do padrão)
5	Consistência	Caixa alta/baixa inconsistente (predial, Predial, PREDIAL, lvr001...)	equipamento 1.006; nome 19; tag 29	UPPER(TRIM) em todos os textos; 7.608 códigos viram 7.221
6	Consistência	Variações no formato da tag (6 formatos; dominante 9.999.9.9999)	127 fora do dominante	Mantidas: são códigos técnicos plausíveis (só padronizadas em maiúsculas)
7	Unicidade	Duplicatas de OM	0	Nenhuma ação; deduplicação por ordem mantida no ETL
8	Unicidade	Equipamento com mais de uma tag	181	Tag mantida na tabela fato (decisão de modelagem)
9	Acurácia	Término anterior ao início (frequentemente só o ano parece errado)	669 (2,8% das terminadas)	Mantidas + flag_termino_antes_inicio; excluídas do cálculo de duração
10	Acurácia	data_manutencao fora de 2026 (2022 a 2025 e 2027)	461	Mantidas + flag_manutencao_fora_2026; não usadas como data de referência
11	Outliers	Duração acima do limite IQR (28,5 dias)	1.424 (6,1%)	Mantidos (manutenções longas são reais); análises usam mediana ao lado da média

Evidências: Completude

1. COMPLETEDE - quantos valores vazios existem em cada coluna?

Contamos como "vazio" tanto o NULL quanto o texto em branco ("").

```

1 SELECT
2   COUNT(*)
3   SUM(CASE WHEN linha IS NULL OR TRIM(linha) = '' THEN 1 ELSE 0 END) AS total_linhas,
4   SUM(CASE WHEN ordem IS NULL OR TRIM(ordem) = '' THEN 1 ELSE 0 END) AS vazios_ordem,
5   SUM(CASE WHEN equipamento IS NULL OR TRIM(equipamento) = '' THEN 1 ELSE 0 END) AS vazios_equipamento,
6   SUM(CASE WHEN nome_equipamento IS NULL OR TRIM(nome_equipamento) = '' THEN 1 ELSE 0 END) AS vazios_nome_equipamento,
7   SUM(CASE WHEN tag IS NULL OR TRIM(tag) = '' THEN 1 ELSE 0 END) AS vazios_tag,
8   SUM(CASE WHEN tipo_manutencao IS NULL OR TRIM(tipo_manutencao) = '' THEN 1 ELSE 0 END) AS vazios_tipo_manutencao,
9   SUM(CASE WHEN data_manutencao IS NULL OR TRIM(data_manutencao) = '' THEN 1 ELSE 0 END) AS vazios_data_manutencao,
10  SUM(CASE WHEN data_termino IS NULL OR TRIM(data_termino) = '' THEN 1 ELSE 0 END) AS vazios_data_termino,
11  SUM(CASE WHEN data_inicio_original IS NULL OR TRIM(data_inicio_original) = '' THEN 1 ELSE 0 END) AS vazios_data_inicio_original,
12  SUM(CASE WHEN estado_om IS NULL OR TRIM(estado_om) = '' THEN 1 ELSE 0 END) AS vazios_estado_om
13 FROM workspace.bronze.om_manutencao_raw;
14 -- Esperado: tag = 7 e data_termino = 1965. Todas as demais colunas = 0.

```

total_linhas	vazios_linha	vazios_ordem	vazios_equipamento	vazios_nome_equipamento	vazios_tag	vazios_tipo_manutencao	vazios_data_manutencao
25872	0	0	0	0	7	0	0

```

1 -- As 7 linhas sem tag: quais são?
2 SELECT linha, ordem, equipamento, nome_equipamento, tipo_manutencao, estado_om
3 FROM workspace.bronze.om_manutencao_raw
4 WHERE tag IS NULL OR TRIM(tag) = '';

```

```

1 -- Os 1965 vazios em data_termino são um PROBLEMA ou algo NORMAL?
2 -- Hipótese: uma OM que ainda não terminou naturalmente não tem data de término.
3 SELECT
4   upper(estado_om) AS estado_om,
5   COUNT(*) AS qtd_om,
6   SUM(CASE WHEN data_termino IS NULL OR TRIM(data_termino) = '' THEN 1 ELSE 0 END) AS sem_data_termino
7 FROM workspace.bronze.om_manutencao_raw
8 GROUP BY upper(estado_om)
9 ORDER BY qtd_om DESC;
10 -- Esperado: TERMINADA tem 0 sem data de término; os demais estados têm 100% sem data. => vazio JUSTIFICÁVEL, não é erro.

```

estado_om	qtd_om	sem_data_termino
TERMINADA	23907	0
SUSPENSÃO	1031	1031
NÃO INICIADA	665	665
INICIADA	269	269

```

1 -- As 7 linhas sem tag: quais são?
2 SELECT linha, ordem, equipamento, nome_equipamento, tipo_manutencao, estado_om
3 FROM workspace.bronze.om_manutencao_raw
4 WHERE tag IS NULL OR TRIM(tag) = '';

```

linha	ordem	equipamento	nome_equipamento	tipo_manutencao	estado_om
1931	200105018	PREDIAL	MANUTENÇÃO PREDIAL	CORRETIVA PLANEJADA	Terminada
8845	200109218	REV035	REVISORA	CORRETIVA PLANEJADA	Terminada
12471	200110811	predial	MANUTENÇÃO PREDIAL	CORRETIVA PLANEJADA	Terminada
18551	200114949	PREDIAL	MANUTENÇÃO PREDIAL	CORRETIVA PLANEJADA	Terminada
18939	200115255	PREDIAL	MANUTENÇÃO PREDIAL	APOIO OPERACIONAL	Terminada
23482	100056045	PREDIAL	MANUTENÇÃO PREDIAL	APOIO A PROJETOS	Terminada
23865	200118633	PREDIAL	MANUTENÇÃO PREDIAL	CORRETIVA PLANEJADA	Terminada

Figura 11 – Evidências de Completude - contagem de vazios por coluna, e vazios de data_termino por estado da OM.

Evidências: Consistência

2. CONSISTÊNCIA - formato e padronização

```

7
1 -- 2.1 As datas seguem o formato dd/MM/yyyy? E há anos "impossíveis" (ex.: 0026)?
2 SELECT 'data_manutencao' AS coluna,
3       SUM(CASE WHEN data_manutencao IS NOT NULL AND NOT data_manutencao RLIKE '[0-9]{2}/[0-9]{2}/[0-9]{4}$' THEN 1 ELSE 0 END) AS fora_do_formato,
4       SUM(CASE WHEN data_manutencao RLIKE '/00[0-9]{2}$' THEN 1 ELSE 0 END) AS ano_impossivel_00xx
5 FROM workspace.bronze.om_manutencao_raw
6 UNION ALL
7 SELECT 'data_termino',
8       SUM(CASE WHEN data_termino IS NOT NULL AND NOT data_termino RLIKE '[0-9]{2}/[0-9]{2}/[0-9]{4}$' THEN 1 ELSE 0 END),
9       SUM(CASE WHEN data_termino RLIKE '/00[0-9]{2}$' THEN 1 ELSE 0 END)
10 FROM workspace.bronze.om_manutencao_raw
11 UNION ALL
12 SELECT 'data_inicio_original',
13       SUM(CASE WHEN data_inicio_original IS NOT NULL AND NOT data_inicio_original RLIKE '[0-9]{2}/[0-9]{2}/[0-9]{4}$' THEN 1 ELSE 0 END),
14       SUM(CASE WHEN data_inicio_original RLIKE '/00[0-9]{2}$' THEN 1 ELSE 0 END)
15 FROM workspace.bronze.om_manutencao_raw;
16 -- Esperado: fora_do_formato = 0 nas três; ano_impossivel_00xx = 1 em data_manutencao e 1 em data_termino (mesma linha).

```

See performance (1) Checked for improvements

Table	+	🔍	🔍	🔍
1	data_manutencao	fora_do_formato	0	1
2	data_termino		0	1
3	data_inicio_origi...		0	0

```

8
1 -- Qual é a linha com o ano impossível?
2 SELECT linha, ordem, equipamento, tipo_manutencao, data_manutencao, data_termino, data_inicio_original
3 FROM workspace.bronze.om_manutencao_raw
4 WHERE data_manutencao RLIKE '/00[0-9]{2}$' OR data_termino RLIKE '/00[0-9]{2}$' OR data_inicio_original RLIKE '/00[0-9]{2}$';
5 -- Esperado: linha 1, com 28/04/0026. O início original é 17/04/2026 => é claramente um erro de digitação de 2026.

```

See performance (1) Checked for improvements

Table	+	🔍	🔍	🔍	🔍	🔍	🔍
1	linha	ordem	equipamento	tipo_manutencao	data_manutencao	data_termino	data_inicio_original
1	300144284	W1184	PREVENTIVA	28/04/0026	28/04/0026	17/04/2026	

1 row 2.223s runtime Refreshed 12m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

```

9
1 -- 2.2 Padronização de texto: valores que mudam ao passar para MAIÚSCULAS (ex.: "predial" x "PREDIAL")
2 SELECT 'equipamento' AS coluna,
3       SUM(CASE WHEN equipamento <> upper(trim(equipamento)) THEN 1 ELSE 0 END) AS linhas_com_caixa_inconsistente,
4       COUNT(DISTINCT equipamento) AS distintos_original,
5       COUNT(DISTINCT upper(trim(equipamento))) AS distintos_padronizado
6 FROM workspace.bronze.om_manutencao_raw
7 UNION ALL
8 SELECT 'nome_equipamento',
9       SUM(CASE WHEN nome_equipamento <> upper(trim(nome_equipamento)) THEN 1 ELSE 0 END),
10      COUNT(DISTINCT nome_equipamento),
11      COUNT(DISTINCT upper(trim(nome_equipamento)))
12 FROM workspace.bronze.om_manutencao_raw
13 UNION ALL
14 SELECT 'tag',
15       SUM(CASE WHEN tag <> upper(trim(tag)) THEN 1 ELSE 0 END),
16       COUNT(DISTINCT tag),
17       COUNT(DISTINCT upper(trim(tag)))
18 FROM workspace.bronze.om_manutencao_raw;
19 -- Esperado: equipamento = 1006 linhas (7608 códigos distintos viram 7221 depois de padronizar);
20 -- nome_equipamento = 19 linhas (656 -> 656); tag = 29 linhas (1591 -> 1585).
21 -- Ou seja: o mesmo equipamento estava sendo contado como se fossem equipamentos diferentes.

```

See performance (1) Checked for improvements

Table	+	🔍	🔍	🔍	🔍
1	equipamento	linhas_com_caixa_inconsistente	1006	7608	7221
2	nome_equipamen...		19	656	656
3	tag		29	1591	1585

MVP - Data Engineering

Pipeline de Dados na Nuvem

06:25 PM (2s) 10

```

1 -- Exemplos concretos do problema de caixa:
2 SELECT equipamento, COUNT(*) AS qtd
3 FROM workspace.bronze.om_manutencao_raw
4 WHERE equipamento <> upper(equipamento)
5 GROUP BY equipamento
6 ORDER BY qtd DESC
7 LIMIT 10;

```

See performance (1) ✓ Checked for improvements

equipamento	qtd
predial	245
Predial	85
lv001	14
slp099	9
lv068	8
av007	8
env001	5
env006	5
rev005	4
sw028	4

10 rows 2.381s runtime Refreshed 12m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

06:25 PM (2s) 11

```

1 -- 2.3 Domínio (valores permitidos) das colunas categóricas
2 SELECT 'tipo_manutencao' AS coluna, tipo_manutencao AS valor, COUNT(*) AS qtd FROM workspace.bronze.om_manutencao_raw GROUP BY tipo_manutencao
3 UNION ALL
4 SELECT 'estado_om', estado_om, COUNT(*) FROM workspace.bronze.om_manutencao_raw GROUP BY estado_om
5 ORDER BY coluna, qtd DESC;
6 -- Esperado: 16 tipos de manutenção e 4 estados (Terminada, Suspensa, Não Iniciada, Iniciada), sem variações de escrita.

```

See performance (1) ✓ Checked for improvements

coluna	valor	qtd
tipo_manutenc...	PREVENTIVA	7333
tipo_manutenc...	INSPEÇÃO	5460
tipo_manutenc...	CORRETIVA EMERGENCIAL	1240
tipo_manutenc...	ADMINISTRAÇÃO DE USUÁRIOS	1066
tipo_manutenc...	APOIO OPERACIONAL	678
tipo_manutenc...	ROTEIRO DE INSPEÇÃO	560
tipo_manutenc...	MODIFICAÇÃO/MELHORIA	456
tipo_manutenc...	LUBRIFICAÇÃO	258
tipo_manutenc...	COMISSIONAMENTO/DESCOMISSONAMENTO	181
tipo_manutenc...	APOIO A PROJETOS	181
tipo_manutenc...	INSTALAÇÃO	82
tipo_manutenc...	LEVANTAMENTO TÉCNICO	71
tipo_manutenc...	QUALIFICAÇÃO	48
tipo_manutenc...	CALIBRAÇÃO	10
tipo_manutenc...	TREINAMENTO	2

20 rows 2.400s runtime Refreshed 13m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

06:25 PM (2s) 12

```

1 -- 2.4 Padrão do campo "ordem" (esperado: 9 dígitos numéricos) e do campo "tag"
2 SELECT
3 SUM(CASE WHEN NOT ordem RLIKE '^[0-9]{9}$' THEN 1 ELSE 0 END) AS ordem_fora_do_padrao_9_digitos
4 FROM workspace.bronze.om_manutencao_raw;

```

See performance (1) ✓ Checked for improvements

ordem_fora_do_padrao_9_digitos
0

1 row 2.178s runtime Refreshed 13m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

MVP - Data Engineering Pipeline de Dados na Nuvem

06:25 PM (3)

```

1 -- Formatos de tag encontrados (9 = dígito, A = letra). O padrão dominante é 9.999.9.9999.
2 SELECT
3   regexp_replace(regexp_replace(upper(tag), '[0-9]', '9'), '[A-Z]', 'A') AS formato_tag,
4   COUNT(*) AS qtd
5 FROM workspace.bronze.om_manutencao_raw
6 WHERE tag IS NOT NULL
7 GROUP BY 1
8 ORDER BY qtd DESC;
9 -- Esperado: 6 formatos. Variações (letra no lugar de dígito, ou 2 dígitos no 1º bloco) são raras e
10 -- plausíveis para um código de identificação técnica; por isso foram MANTIDAS (só padronizadas em maiúsculas).

```

See performance (1)

Table

	formato_tag	qtd
1	9.999.9.9999	23906
2	9.999.A.9999	897
3	9.999.9.999A	855
4	99.99.9.9999	71
5	9.999.9.9999A	55
6	9.999.9.999AA	1

6 rows 2.599s runtime

Refreshed 13m ago

This result is stored as _sqlidf and can be used in other Python and SQL cells.

Figura 12 – Evidência de Consistência: datas fora do formato / ano 00xx, e caixa inconsistente em equipamento, nome e tag.

Evidências: Unicidade

3. UNICIDADE - duplicatas

06:25 PM (2)

```

1 SELECT
2   COUNT(*) AS total_linhas,
3   COUNT(DISTINCT ordem) AS ordens_distintas,
4   COUNT(*) - COUNT(DISTINCT ordem) AS ordens_duplicadas
5 FROM workspace.bronze.om_manutencao_raw;
6 -- Esperado: 25872 linhas, 25872 ordens distintas, 0 duplicatas. O número da OM funciona como chave primária.

```

See performance (1)

Table

	total_linhas	ordens_distintas	ordens_duplicadas
1	25872	25872	0

1 row 2.466s runtime

Refreshed 13m ago

This result is stored as _sqlidf and can be used in other Python and SQL cells.

06:25 PM (3)

```

1 -- Linhas 100% idênticas (ignorando o número da linha e os metadados de carga):
2 SELECT COUNT(*) AS grupos_de_linhas_identicas FROM (
3   SELECT ordem, equipamento, nome_equipamento, tag, tipo_manutencao, data_manutencao, data_termino, data_inicio_original, estado_om
4   FROM workspace.bronze.om_manutencao_raw
5   GROUP BY ALL
6   HAVING COUNT(*) > 1
7 );
8 -- Esperado: 0.

```

See performance (1)

Table

	grupos_de_linhas_identicas
1	0

1 row 2.861s runtime

Refreshed 13m ago

This result is stored as _sqlidf and can be used in other Python and SQL cells.

MVP - Data Engineering

Pipeline de Dados na Nuvem




Figura 13 – Evidência de Unicidade: ordens duplicadas (0) e equipamentos com mais de uma tag (181).

Evidências: Acurácia



MVP - Data Engineering

Pipeline de Dados na Nuvem

06:25 PM (3s) 21

```

1 -- 4.1 Intervalo de cada data: faz sentido estar tudo em 2026?
2 SELECT 'data_inicio_original' AS coluna, MIN(data_inicio_original) AS minima, MAX(data_inicio_original) AS maxima FROM vw_dados
3 UNION ALL SELECT 'data_termino', MIN(data_termino), MAX(data_termino) FROM vw_dados
4 UNION ALL SELECT 'data_manutencao', MIN(data_manutencao), MAX(data_manutencao) FROM vw_dados;
5 -- Esperado: início entre 01/01/2026 e 31/08/2026 (o recorte do arquivo).
6 -- término e manutenção têm datas de 2022, 2023, 2025 e até 2027 => suspeito.

```

See performance (1) ✓ Checked for improvements

coluna	minima	maxima
data_inicio_origi...	2026-01-01	2026-08-31
data_termino	2023-03-15	2026-09-04
data_manutencao	2022-11-28	2027-08-23

3 rows 3.488s runtime Refreshed 15m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

06:25 PM (3s) 22

```

1 -- 4.2 Distribuição do ANO de cada data. Quase tudo deveria ser 2026.
2 SELECT year(data_manutencao) AS ano, COUNT(*) AS qtd_data_manutencao
3 FROM vw_dados GROUP BY year(data_manutencao) ORDER BY ano;
4 -- Esperado: 2022 (1), 2023 (3), 2024 (4), 2025 (439), 2026 (25410 + 1 corrigida = 25411), 2027 (14).

```

See performance (1) ✓ Checked for improvements

ano	qtd_data_manutencao
2022	1
2023	3
2024	4
2025	439
2026	25410
2027	14

7 rows 2.596s runtime Refreshed 15m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

06:25 PM (3s) 23

```

1 -- 4.3 Término ANTES do início: fisicamente estranho
2 SELECT
3 COUNT(*) AS oms_terminadas,
4 SUM(CASE WHEN data_termino < data_inicio_original THEN 1 ELSE 0 END) AS termino_antes_do_inicio,
5 ROUND(100.0 * SUM(CASE WHEN data_termino < data_inicio_original THEN 1 ELSE 0 END) / COUNT(*), 2) AS pct
6 FROM vw_dados
7 WHERE data_termino IS NOT NULL;
8 -- Esperado: 669 casos (~2,8% das OMs terminadas).

```

See performance (1) ✓ Checked for improvements

oms_terminadas	termino_antes_do_inicio	pct
23906	669	2.80

1 row 2.691s runtime Refreshed 15m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

MVP - Data Engineering

Pipeline de Dados na Nuvem

06:25 PM (G) 24

```

1 -- Exemplos: repare que muitas vezes só o ANO parece errado (ex.: término 22/04/2025 com início 22/04/2026)
2 SELECT ordem, tipo_manutencao, data_inicio_original, data_manutencao, data_termino,
3       datediff(data_termino, data_inicio_original) AS dias
4 FROM vw_dados
5 WHERE data_termino < data_inicio_original
6 ORDER BY dias ASC
7 LIMIT 15;

```

See performance (f) ✓ Checked for improvements

ordem	tipo_manutencao	data_inicio_original	data_manutencao	data_termino	dias
300141024	INSPEÇÃO	2026-03-13	2023-03-15	2023-03-15	-1094
200110860	CORRETIVA EMERGENCIAL	2026-04-22	2025-04-22	2025-04-22	-365
200110915	CORRETIVA PLANEJADA	2026-04-22	2025-04-25	2025-04-25	-362
300154936	PREVENTIVA	2026-08-01	2026-06-03	2026-06-03	-59
300154918	PREVENTIVA	2026-08-01	2026-06-03	2026-06-03	-59
300154935	PREVENTIVA	2026-08-01	2026-06-03	2026-06-03	-59
200117361	CORRETIVA PLANEJADA	2026-07-28	2026-06-08	2026-06-08	-50
200115278	CORRETIVA PLANEJADA	2026-06-26	2026-05-15	2026-05-15	-42
300112436	APOIO OPERACIONAL	2026-05-18	2026-04-16	2026-04-16	-32
200104508	CORRETIVA EMERGENCIAL	2026-02-04	2026-01-03	2026-01-03	-32
200111495	CORRETIVA EMERGENCIAL	2026-05-04	2026-04-03	2026-04-03	-31
200115640	CORRETIVA EMERGENCIAL	2026-07-03	2026-06-03	2026-06-03	-30
200105883	CORRETIVA EMERGENCIAL	2026-02-23	2026-01-24	2026-01-24	-30
300136716	PREVENTIVA	2026-02-02	2026-01-04	2026-01-04	-29
200110443	CORRETIVA PLANEJADA	2026-04-13	2026-03-17	2026-03-17	-27

15 rows 2.989s runtime Refreshed 15m ago

This result is stored as _sqlidf and can be used in other Python and SQL cells.

Figura 14 – Evidência de Acurácia: término anterior ao início (669) e distribuição do ano de data_manutencao.

Evidências: Acurácia




Figura 15 – Evidência de Outliers: estatísticas de duração (mediana, média, limite IQR e quantidade de outliers).

Análise de Dados

Todas as análises foram feitas em SQL sobre a camada Gold (06_analise_perguntas), com data de referência data_inicio_original. Abaixo, para cada pergunta: o resultado (evidência) e a discussão. Resultados numéricos citados foram conferidos contra o resultado do Databricks.

Pergunta 1:

Carga de trabalho: qual é a composição das OMs por grupo de manutenção (preventiva/inspeção, corretiva, projetos/melhorias, apoio) e por mês? Qual a proporção entre preventivas e corretivas?




Figura 16 – Distribuição dos dados por grupo de manutenção ao longo do período analisado




Figura 17 – Script do gráfico de Distribuição dos dados por grupo de manutenção ao longo do período analisado

Análise:

O volume total de Ordens de Manutenção se apresenta estável, entre ~2.700 e ~3.500 OMs por mês. Um discreto aumento é observado nos meses de janeiro e março (~3.450–3.520), o mês de janeiro pode ser justificado devido ao período de parada de produção e maior disponibilidade para atuação nas áreas produtivas. O vale em fevereiro (~2.740), pode ser justificado devido ao período de baixa na produção por motivo de feriados prolongados e menor demanda de subestações e equipamentos críticos, sendo coerente com um mês mais curto.

Composição:

- **Preventiva/Inspeção** (verde) é o maior grupo, com cerca de 1.500 a 2.000 OMs/mês, aproximadamente 50–58% do total. Atingiu o máximo em março (~1.984).
- **Corretiva** (amarelo) é o segundo maior, com ~900 a 1.300 OMs/mês. Foi mais alta em janeiro (1.300) e março (1.235) e menor em fevereiro (934) e abril (1.040), com leve recuperação depois.
- **Apoio/Administrativo** (azul) é pequeno e estável, ~180–270 OMs/mês.
- **Projetos/Melhorias** (vermelho) é o menor, mas mostra tendência de crescimento: de ~37–90 OMs no início do ano para algo em torno de 250 em julho, o maior valor da série.

A proporção corretiva/preventiva fica em torno de 35–40% do total, podendo ser aplicável um plano de ação para redução das corretivas.

Em julho houve maior crescimento de projetos/melhorias e apoio, com o total voltando perto de 3.450. É possível criar uma ação para identificar possibilidade de distribuição destas Ordens ao longo o ano.

Em agosto houve queda das ordens preventivas (~1.580) em relação a março, o que mostra eficiência na realização do plano de preventivas, sempre voltado para períodos de parada de produção.

Pergunta 2:

Equipamentos problemáticos: quais classes de equipamento concentram mais OMs corretivas (planejadas e emergenciais)?

Nota: Para esta análise foram desconsideradas ordens de Manutenção em que a identificação do equipamento era “Predial”, e ordens que não fossem do tipo corretiva e preventiva pois a proposta desta pergunta é atacar equipamentos que poderiam estar causando parada de produção ou sobrecarregando a equipe de manutenção.




Figura 18 – Distribuição dos dados por tipo de equipamento e tipo de manutenção

```

1 --Opção 2
2 -- 2b) Top 10 classes de equipamento por OMs corretivas: composição das OMs
3 SELECT
4   e.classe Equipamento,
5   e.nome_classe,
6   COUNT(*) AS total_om,
7   SUM(CASE WHEN t.grupo_manutencao = 'CORRETIVA' THEN 1 ELSE 0 END) AS qtd_corretivas,
8   SUM(CASE WHEN f.tipo_manutencao = 'CORRETIVA EMERGENCIAL' THEN 1 ELSE 0 END) AS qtd_emergenciais,
9   SUM(CASE WHEN t.grupo_manutencao = 'CORRETIVA'
10      AND f.tipo_manutencao <> 'CORRETIVA EMERGENCIAL' THEN 1 ELSE 0 END) AS qtd_corretivas_comuns,
11   SUM(CASE WHEN t.grupo_manutencao <> 'CORRETIVA' THEN 1 ELSE 0 END) AS qtd_outras_om,
12   ROUND(100.0 * SUM(CASE WHEN t.grupo_manutencao = 'CORRETIVA' THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_corretiva
13 FROM workspace.gold.fato_ordem_manutencao f
14 JOIN workspace.gold.dim_equipamento e ON f.cod_equipamento = e.cod_equipamento
15 JOIN workspace.gold.dim_tipo_manutencao t ON f.tipo_manutencao = t.tipo_manutencao
16 WHERE e.classe_equipamento <> 'PREDIAL'
17 GROUP BY e.classe_equipamento, e.nome_classe
18 ORDER BY qtd_corretivas DESC
19 LIMIT 10;

```

Figura 19 – Script do gráfico de Distribuição dos dados por tipo de equipamento e tipo de manutenção

Análise:

O tipo de equipamento Fancoil foi a única classe de destaque em relação às ordens corretivas emergenciais. As 359 emergenciais representam ~27% de todas as OMs deste tipo de equipamento, e somadas às 444 corretivas comuns, ~59% do total é corretivo. Mostrando que a manutenção reativa é dominante neste grupo.

As Autoclaves apresentam maior quantitativo de “outras ordens”, ou seja, ordens que não são caracterizadas como corretivas (910, ~70%). Apresentou 169 emergenciais, o segundo maior valor, mas

MVP - Data Engineering

Pipeline de Dados na Nuvem

em menor proporção (~13%). O volume alto vem de rotina planejada, o que mostra que as preventivas estão ocorrendo normalmente.

Equipamentos de Contadores de Partículas, Freezers e Ar Condicionados Split apresentaram ~70% ou mais de OMs planejadas, poucas corretivas comuns (184 a 201) e emergenciais quase nulas (0, ~3 e ~20). Demonstrando que não são equipamentos mais controlados.

As Câmaras Frias apresentam 66 emergenciais e 142 corretivas comuns contra só 111 planejadas. É a segunda classe com maior proporção reativa (~65%), e as emergenciais, em vermelho, demonstram no gráfico (~21% das OMs), o que sugere atenção e ações para redução destas ocorrências.

Os purificadores de água apresentaram apenas ordens corretivas, barra inteiramente amarela, (174 corretivas comuns + 1 emergencial) e nenhuma OM planejada. É o caso mais claro de ausência de preventiva.

Módulo de Fluxo, Lavadora e Tanque de Meios foram os perfis mais equilibrados, com corretivas comuns (107 a 120) próximas ou menores que as planejadas (131 a 232), e emergenciais baixas (~12 a 14).

Sugestões de ações:

- **Fancoil e Câmara Fria** concentram as emergenciais e têm mais OMs reativas que planejadas: prioridade para análise de causa raiz e revisão do plano preventivo.
- **Purificador de Água** devem ser verificados os planos de preventivas para esta categoria ou se há problema de cadastro.
- Fancoil e Autoclave somam ~528 das ~657 emergenciais do Top 10 (~80%). Construir planos de ação voltados para essas duas classes poderá reduzir a maior parte das paradas emergenciais.

Pergunta 3:

Conclusão e backlog: qual a taxa de conclusão das OMs por grupo e por tipo de manutenção? Onde se concentram as OMs suspensas e não iniciadas?





Figura 20 –Gráfico de taxa de conclusão das ordens de manutenção por tipo



```

1 -- 3a) Estado das OMs por grupo, em quantidade e percentual
2 SELECT
3     t.grupo_manutencao,
4     COUNT(*)
5     SUM(CASE WHEN f.estado_om = 'TERMINADA' THEN 1 ELSE 0 END) AS total_om,
6     SUM(CASE WHEN f.estado_om = 'INICIADA' THEN 1 ELSE 0 END) AS terminadas,
7     SUM(CASE WHEN f.estado_om = 'NÃO INICIADA' THEN 1 ELSE 0 END) AS iniciadas,
8     SUM(CASE WHEN f.estado_om = 'SUSPensa' THEN 1 ELSE 0 END) AS nao_iniciadas,
9     ROUND(100.0 * SUM(CASE WHEN f.estado_om = 'TERMINADA' THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_terminadas
10 FROM workspace.gold.fato_ordem_manutencao f
11 JOIN workspace.gold.dim_tipo_manutencao t ON f.tipo_manutencao = t.tipo_manutencao
12 GROUP BY t.grupo_manutencao
13 ORDER BY pct_terminadas;
14

```

Figura 21 – Script do gráfico de taxa de conclusão das ordens de manutenção

Análise:

Os dados mostram que em geral a taxa de execução é alta em todos os grupos, mas os grupos reativos e de projetos concentram os problemas de andamento. O que não foi concluído está sobretudo em suspensas e não iniciadas.

- **Preventiva/Inspeção** (98,4%): praticamente tudo concluído. Restam 201 não iniciadas (~1,5%), 12 iniciadas e nenhuma suspensa. É o grupo com melhor aderência ao plano.
- **Apoio/Administrativo** (97,3%): resíduo muito pequeno (16 iniciadas, 16 não iniciadas, 15 suspensas).
- **Corretiva** (84,6%): tem a maior faixa vermelha entre os grupos grandes. As 913 suspensas representam ~9,6% das OMs, e há mais 348 não iniciadas (~3,7%) e 201 em andamento.
- **Projetos/Melhorias** (76,2%): o menor percentual de conclusão. Tem ~10% suspensas (103) e ~10% não iniciadas (100), além de 40 iniciadas (~4%).

Sugestão de ações:

- As **913 suspensas da Corretiva** são o maior passivo em números absolutos (mais de 8 vezes as suspensas de Projetos). Vale investigar os motivos (falta de peça, aguardando aprovação, parada de equipamento indisponível) e o tempo de suspensão.
- **Projetos/Melhorias** tem o pior desempenho relativo, mas é um grupo pequeno (1.019 OMs). Suspensão e não início comuns são esperados em projetos, mas ~20% sem andamento merece revisão de priorização ou análise de real necessidade destas ordens.
- As **201 não iniciadas da Preventiva** são o único desvio do grupo. Deve-se avaliar se são OMs antigas, vencidas ou recém-geradas para identificar possíveis falhas nos planos de preventivas.

Pergunta 4:

Tempo de execução: quanto tempo (mediana e média, em dias) as manutenções levam, por grupo e por tipo?




Figura 22 – Gráfico de análise de tempo de execução de ordens

```

1 -- 4a) Duração por grupo
2 SELECT
3   t.grupo_manutencao,
4   COUNT(f.duracao_dias) AS oms_com_duracao,
5   percentile(f.duracao_dias, 0.5) AS mediana_dias,
6   ROUND(AVG(f.duracao_dias), 1) AS media_dias,
7   MAX(f.duracao_dias) AS maximo_dias
8 FROM workspace.gold.fato_ordem_manutencao f
9 JOIN workspace.gold.dim_tipo_manutencao t ON f.tipo_manutencao = t.tipo_manutencao
10 GROUP BY t.grupo_manutencao
11 ORDER BY mediana_dias DESC;
12

```

Figura 23 – Script do Gráfico de análise de tempo de execução de ordens

Análise:

Foi possível identificar em todos os grupos que a média é maior que a mediana, o que indica distribuições assimétricas à direita: a maioria das OMs fecha rápido, mas um grupo menor de OMs longas puxa a média para cima. Sendo assim mais recomendável utilizar a mediana como medida de tempo em dashboards e análises futuras.

Nota: as médias consideram apenas ordens em que foi possível calcular a duração, ou seja, ordens que já foram terminadas e que possuem datas de término.

Análise por grupo:

- **Corretiva:** o maior contraste relativo. A mediana é de só 2 dias, mas a média é de 9,5 (~4,7 vezes maior). A maioria dos reparos é rápida, mas há casos muito longos, com máximo de 217 dias, o maior de todos os grupos.
- **Projetos/Melhorias:** tem a maior média (11,8) e mediana de 5 dias. Duração alta em geral, coerente com a natureza dessas OMs, e com cauda longa (máximo de 130).
- **Preventiva/Inspeção:** a maior mediana (6) e média de 9,4, a mais próxima da mediana entre os grupos grandes. As durações são maiores, porém mais regulares, o que é esperado em atividades planejadas. O máximo é 194 dias.
- **Apoio/Administrativo:** as menores durações (mediana 2, média 5,6), com poucos casos extremos, embora o máximo chegue a 161 dias.

Sugestão de ações:

Avaliar as ordens suspensas, pois a cauda longa nas Corretivas, com mediana de 2 dias, uma média de 9,5 e máximo de 217 dias, são acima de 30 dias. São as que mais pesam no indicador de tempo de reparo, indicando que a falta de material para execução pode estar atrelada diretamente ao aumento destes tempos.

Avaliar as ordens com tempos acima de 100 dias em todos os grupos (inclusive Apoio, com 161 e Preventiva, com 194): podem ser OMs esquecidas em aberto, encerradas tardiamente ou erro de data.

Pergunta 5:

Evolução mensal: como evoluíram, de janeiro a agosto, o volume de OMs, a taxa de conclusão e as corretivas emergenciais?




Tabela 24 – Gráfico de evolução mensal das ordens terminadas




Tabela 25 – Script para gráfico de evolução mensal das ordens terminadas

Análise:

O volume mensal de ordens abertas é estável. As barras ficam entre 2,74 mil (fevereiro, o mês mais baixo) e 3,52 mil OMs (março, o mais alto), somando as 25.872 ordens do período. Não há tendência de alta nem de queda, no geral a demanda de manutenção é regular, com variação de cerca de 20% entre o menor e o maior mês.

O ponto de atenção é que a taxa de conclusão cai de forma progressiva, mostrando:

Período Taxa de conclusão

Jan a Mai entre 97,1% e 94,9%

Junho 92,2%

Julho 89,4%

Agosto 79,1%

A queda é leve até maio (cerca de 2 pontos), acelera em junho e julho e é forte em agosto (10 pontos a menos que em julho). Em agosto, cerca de 1 em cada 5 OMs ainda não foi terminada.

É importante destacar que a queda não vem do volume de ordens abertas, pois este número se mantém na mesma faixa. Agosto (3,24 mil) tem quase o mesmo número de OMs que janeiro (3,46 mil), mas 18 pontos percentuais a menos de conclusão. Fevereiro teve o menor volume e ainda assim uma taxa alta (96,1%). Isso demonstra o impacto no tempo de fechamento das ordens, dado que a base de dados foi extraída em agosto e possíveis problemas para na capacidade de fechar as ordens.

Deve ser feita uma análise focada no acúmulo real de pendências (backlog). A queda já aparece em junho, quando a maioria das OMs deveria estar fechada. Isso sugere um acúmulo de ordens abertas que merece investigação (equipe, peças, priorização das emergenciais).

É recomendado acompanhar as OMs abertas há mais de 30 dias.

Considerações Finais

Este trabalho construiu, na plataforma Databricks, um pipeline de dados em três camadas (Bronze, Silver e Gold) a partir de 25.872 ordens de manutenção (OMs) de janeiro a agosto de 2026. Nenhuma linha foi perdida ao longo do processo: o volume se manteve igual em todas as camadas. Os problemas de qualidade encontrados, como o ano digitado incorretamente e variações de maiúsculas e minúsculas. Foi verificado com as equipes que os dados com datas de término anteriores ao início se trata de irregularidades no fluxo do processo e foram sinalizadas ações para evitar estes erros. Com isso, as análises puderam usar dados confiáveis sem apagar informação da fonte.

A análise mostrou que a manutenção é dominada por atividades preventivas e de inspeção (52,7% das OMs), seguidas pelas corretivas (36,7%). A taxa geral de conclusão foi de 92,4%, com diferenças importantes entre os grupos: alta nas preventivas (98,4%) e mais baixa nas corretivas (84,6%) e nos projetos e melhorias (76,2%). Entre as corretivas, a classe predial foi desconsiderada na análise de equipamentos, mas concentra a maior parte das ordens (41,3%), enquanto, entre os demais equipamentos, a classe FAC teve o maior número de ocorrências. Para isto, recomendou-se para as equipes de manutenção identificar melhor a tipologia “PREDIAL” para melhoria das análises futuras.

O resultado que mais merece atenção é a evolução mensal: o volume de OMs foi estável (2,7 a 3,5 mil por mês), mas a taxa de conclusão caiu de 97,1% em janeiro para 79,1% em agosto. Parte dessa queda pode ser efeito de OMs recentes ainda em andamento na data da extração e do tempo de execução que as mesmas demandam (maior que 30 dias) mas a redução já visível em junho e julho indica possível acúmulo



MVP - Data Engineering

Pipeline de Dados na Nuvem

de pendências. Recomenda-se acompanhar mensalmente as OMs abertas há mais tempo e investigar a causa da queda, como equipe, peças ou priorização.

Como limitações, o trabalho usa uma única extração, sem data de encerramento planejada. Como próximos passos, o pipeline pode ser agendado para rodar de forma automática e incluir novas cargas mensais.