



Análise Descritiva das Ordens de Manutenção na Indústria Farmacêutica

Aluna: Larissa Mitrof de Lima

E-mail: larissa.mitrof@gmail.com

GitHub: <https://github.com/larissamitrof-collab/MVP-Pipeline>

Discord: larissamitrof

Sprint: Engenharia de Dados (40530010057_20260_01)

SUMÁRIO

Análise Descritiva das Ordens de Manutenção na Indústria Farmacêutica	1
Contexto de Negócio e Perguntas (Etapas 2 e 4.1)	3
Carga de Dados (Etapa 4.2)	4
Licença e uso de dados	4
Carga dos Dados	4
Modelagem e Catálogo de Dados (Etapa 4.3)	6
Catálogo de Dados (Etapa 4.4)	7
Catálogo de Dados Transcrito	9
Pipeline de Dados (Etapa 4.4)	16
Organização do ETL	16
Transformações Realizadas (Silver).....	17
Evidências de persistência e validação	17
Qualidade de Dados (Etapa 4.5)	19
Problemas detectados e como foram resolvidos.....	19
Evidências: Completude	20
Evidências: Consistência	21
Evidências: Unicidade	23
Evidências: Acurácia.....	24
Evidências: Outliers.....	26
Análise de Dados (Etapa 4.5).....	27
Considerações Finais	34
Autoavaliação	34

Contexto de Negócio e Perguntas (Etapas 2 e 4.1)

A análise de dados provenientes das ordens de manutenção em uma indústria farmacêutica é fundamental para garantir a confiabilidade e segurança dos equipamentos, o cumprimento das diretrizes regulatórias e a continuidade dos processos produtivos. Extraídos do ERP TOTVS Datasul no período de 01/01/2026 a 31/08/2026, os dados utilizados oferecem uma visão estruturada sobre a realização e/ou planejamento das manutenções, permitindo avaliar os dados através dos tipos de manutenção realizadas (preventiva, corretiva, emergencial), status, localização e equipamentos envolvidos.

Problema a resolver - Construir um pipeline de dados na nuvem que transforme a exportação bruta de ordens de manutenção em um modelo organizado, documentado e de qualidade verificada para responder a cinco perguntas centrais:

- 1 - Carga de trabalho:** qual é a composição das OMs por grupo de manutenção (preventiva/inspeção, corretiva, projetos/melhorias, apoio) e por mês? Qual a proporção entre preventivas e corretivas?
- 2 - Equipamentos problemáticos:** quais classes de equipamento concentram mais OMs corretivas (planejadas e emergenciais)?
- 3 - Conclusão e backlog:** qual a taxa de conclusão das OMs por grupo e por tipo de manutenção? Onde se concentram as OMs suspensas e não iniciadas?
- 4 - Tempo de execução:** quanto tempo (mediana e média, em dias) as manutenções levam, por grupo e por tipo?
- 5 - Evolução mensal:** como evoluíram, de janeiro a agosto, o volume de OMs, a taxa de conclusão e as corretivas emergenciais?

Dessa forma, o pipeline não apenas permitirá identificar padrões de falhas, avaliar a eficiência das ações de manutenção e antecipar necessidades críticas, mas também garantirá maior segurança operacional e otimização de recursos em um setor altamente regulado e sensível como o farmacêutico.

Os principais objetivos desse pipeline incluem:

- **Organizar e padronizar os dados** extraídos do ERP, garantindo consistência e qualidade da informação.
- **Automatizar o fluxo de análise**, reduzindo o tempo entre a coleta e a geração de insights.
- **Suportar decisões estratégicas**, permitindo priorização de recursos e planejamento de manutenções preventivas.
- **Gerar relatórios e visualizações dinâmicas**, facilitando a comunicação entre áreas técnicas e gerenciais.

Carga de Dados (Etapa 4.2)

O arquivo [om_manutencao_2026.csv](#) (2,83 MB, codificação UTF-8, separador vírgula) contém **25.872 linhas** e **10 colunas**. Cada linha é uma ordem de manutenção; não há tabelas relacionadas, o arquivo é uma tabela única.

Tabela 1 – Descrição dos dados das colunas

Coluna	Descrição	Exemplo
linha	Número sequencial da linha no arquivo	1
ordem	Número da OM (9 dígitos, único)	300144284
equipamento	Código do equipamento (letras da classe + número)	AUT114
nome_equipamento	Descrição do equipamento	AUTOCLAVE
tag	Código técnico/local (formato 9.999.9.9999)	1.023.3.0346
tipo_manutencao	Tipo da OM (16 valores)	PREVENTIVA
data_manutencao	Data da manutenção registrada (texto dd/MM/yyyy)	28/04/2026
data_termino	Data de término (vazia se não terminada)	01/07/2026
data_inicio_original	Data de início originalmente prevista	26/06/2026
estado_om	Terminada, Suspensa, Não Iniciada ou Iniciada	Terminada

Licença e uso de dados

Origem: exportação de relatório do sistema ERP TOTVS Data Sul, tela MI0629. Dados reais internos.

Licença: não se trata de dado aberto e não possui licença pública. O uso é exclusivamente acadêmico deste trabalho na PUC-Rio para posterior aplicação na empresa, mediante autorização da chefia.

Dados pessoais: colunas que pudessem apresentar dados sigilosos foram excluídas na fase de extração dos dados. A base não contém nomes de pessoas ou siglas de departamentos, CPF, matrícula, e-mails ou quaisquer outros dados pessoais ou capazes de caracterizar a instituição. As colunas de ordem, equipamentos, tags, tipos ou datas são colunas identificadoras. Por isso não foi necessária anonimização.

Publicação: o arquivo de dados não foi publicado no repositório por se tratar de dados institucionais.

Carga dos Dados

Coleta e upload: Os dados foram exportados do sistema ERP TOTVS Data Sul em formato CSV e enviado ao Databricks pela interface (Catalog > workspace > bronze > raw_files > Upload to this volume).

Caminho final: /Volumes/workspace/bronze/raw_files/om_manutencao_2026.csv.

Ingestão para tabela: A tabela Delta é gravada (workspace.bronze.om_manutencao_raw), sem alteração de nenhum valor. Todas as colunas entram como texto (inferColumnTypes => false), para preservar exatamente o que veio da fonte, inclusive erros. São adicionadas duas colunas de controle: _arquivo_origem e _ingerido_em, que dão rastreabilidade.

MVP - Data Engineering

Pipeline de Dados na Nuvem




Figura 01 - Volume raw_files no Unity Catalog - arquivo om_manutencao_2026.csv (2,83 MB) carregado.



Figura 02 – Notebook 01: Total de linhas Catalog - arquivo om_manutencao_2026.csv (2,83 MB) carregado.




Figura 03 – Tipos das colunas no Catalog - arquivo om_manutencao_2026.csv (2,83 MB) carregado.

Modelagem e Catálogo de Dados (Etapa 4.3)

O modelo escolhido foi do tipo esquema estrela devido ao objetivo de analisar eventos (Ordens de Manutenção) sob diferentes perspectivas (equipamentos, tipo de manutenção, tempo), permitindo que as consultas sejam simples e rápidas e refletindo diretamente as perguntas de negócio.




Figura 04 – Esquema escolhido para camada Gold.

Tabela 2 – Descrição das tabelas fato e dimensão utilizadas

Tabela	Tipo	Granularidade (1 linha = ...)	Linhas	Para que serve
fato_ordem_manutencao	Fato	1 ordem de manutenção	25.872	Estado, datas, duração e sinalizadores de qualidade de cada OM
dim_equipamento	Dimensão	1 código de equipamento	7.221	Nome e classe do equipamento (ex.: AUT = autoclave)
dim_tipo_manutencao	Dimensão	1 tipo de manutenção	16	Agrupar os tipos em 4 grupos de negócio
dim_data	Dimensão	1 dia (2026 e 2027)	730	Ano, mês, trimestre e dia da semana

Decisões de modelagem

- A coluna tag fica na fato, pois não se trata de uma dimensão, o código reflete a localização, prédio, sala onde o equipamento está localizado: no diagnóstico, 181 equipamentos apareceram associados a mais de uma tag.
- Classe do equipamento: as letras iniciais do código (AUT, CHI, ARS...) formam 225 classes; o nome da classe representa o tipo equipamento mais frequente dentro dela.
- Grupos de manutenção: os 16 tipos foram agrupados em Preventiva/Inspeção, Corretiva, Projetos/Melhorias e Apoio/Administrativo. Foi a decisão de negócio documentada na tabela dim_tipo_manutencao.
- Data de referência: as análises mensais usam data_inicio_original, representando a data de quando a Ordem de manutenção foi gerada no sistema.
- Chaves naturais (código do equipamento, número da OM) em vez de chaves artificiais, foram utilizadas para simplificar o trabalho.

MVP - Data Engineering

Pipeline de Dados na Nuvem




Figura 05 – Árvore Catalog – camadas bronze, silver e gold.

Catálogo de Dados (Etapa 4.4)

O catálogo foi registrado no Unity Catalog (comentários de tabela e de coluna gravados pelo notebook 05, com tipo e linhagem exibidos automaticamente pelo Databricks) e transcrito abaixo. Para cada tabela: descrição, e para cada coluna: descrição, tipo, domínio de valores e linhagem.

Column	Type	Popularity	Comment	Tags	Column masking
ordem	bigint	...	Número da OM (chave da fato). Domínio: Único: 100050417 a 300157661. Linhagem: silver.om_manutencao.ordem.		
cod_equipamento	string		Chave estrangeira para dim_equipamento. Domínio: 7.221 valores. Linhagem: silver.om_manutencao.equipamento.		
tipo_manutencao	string	...	Chave estrangeira para dim_tipo_manutencao. Domínio: 16 valores. Linhagem: silver.om_manutencao.tipo_manutencao.		
data_inicio_original	date		Chave estrangeira para dim_data; data de referência das análises. Domínio: 2026-01-01 a 2026-06-31. Linhagem: silver.om_manutencao.data_inicio_original.		
tag_local	string		Tag (código técnico/local) da OM. Fica na fato porque um equipamento pode ter mais de uma tag. Domínio: 1.585 tags; 7 NULL. Linhagem: silver.om_manutencao.tag.		
estado_om	string	...	Situação da OM. Domínio: TERMINADA, SUSPENSÃO, NÃO INICIADA, INICIADA. Linhagem: silver.om_manutencao.estado_om.		
data_manutencao	date		Data da manutenção registrada na OM. Domínio: 2022-11-28 a 2027-08-23. Linhagem: silver.om_manutencao.data_manutencao.	Add tags	Add column mask

MVP - Data Engineering

Pipeline de Dados na Nuvem

estado_om	string		Situação da OM. Domínio: TERMINADA, SUSPENSA, NÃO INICIADA, INICIADA. Linhagem: silver.om_manutencao.estado_om.
data_manutencao	date	----	Data da manutenção registrada na OM. Domínio: 2022-11-28 a 2027-08-23. Linhagem: silver.om_manutencao.data_manutencao.
data_termino	date	----	Data de término da OM; NULL se não terminada. Domínio: 2023-03-15 a 2026-09-04. Linhagem: silver.om_manutencao.data_termino.
duracao_dias	int		Medida: dias de execução (término - início original). NULL se não aplicável. Domínio: 0 a 217. Linhagem: silver.om_manutencao.duracao_dias.
flag_ano_corrigido	boolean	----	Sinalizador: ano de data corrigido. Domínio: 1 linha true. Linhagem: silver.om_manutencao.flag_ano_corrigido.
flag_termino_antes_inicio	boolean	----	Sinalizador: término anterior ao início. Domínio: 669 linhas true. Linhagem: silver.om_manutencao.flag_termino_antes_inicio.
flag_manutencao_fora_2026	boolean	----	Sinalizador: data_manutencao fora de 2026. Domínio: 461 linhas true. Linhagem: silver.om_manutencao.flag_manutencao_fora_2026.
flag_tag_ausente	boolean	----	Sinalizador: OM sem tag. Domínio: 7 linhas true. Linhagem: silver.om_manutencao.flag_tag_ausente.

Figura 6 –Catalog: Catálogo de Dados- tabela fato (Gold)




Figura 7 –Catalog: Linhagem da tabela fato

Catálogo de Dados Transcrito

[workspace.bronze.om_manutencao_raw \(Bronze\)](#)

Ordens de manutenção (OM) de janeiro a agosto de 2026, exatamente como exportadas do sistema de gestão de manutenção. Nenhum valor foi alterado; todas as colunas originais estão em texto. Granularidade: 1 linha por OM (25.872 linhas). Origem: arquivo om_manutencao_2026.csv, carregado no volume workspace.bronze.raw_files.

Tabela 3 – Descrição dos tipos de dados da camada bronze

Coluna	Tipo	Descrição	Domínio	Linhagem
linha	STRING	Número sequencial da linha no arquivo exportado.	Texto numérico de 1 a 25872.	CSV: coluna linha (sem transformação).
ordem	STRING	Número da ordem de manutenção (OM), identificador único da OM.	Texto numérico de 9 dígitos (100050417 a 300157661).	CSV: coluna ordem (sem transformação).
equipamento	STRING	Código do equipamento: letras da classe + número (ex.: AUT114 = autoclave 114). O código PREDIAL representa manutenção predial geral, sem equipamento específico.	Texto de 4 a 16 caracteres; pode ter minúsculas (problema tratado na Silver).	CSV: coluna equipamento (sem transformação).
nome_equipamento	STRING	Descrição textual do equipamento (ex.: AUTOCLAVE, CHILLER).	656 nomes distintos.	CSV: coluna nome_equipamento (sem transformação).
tag	STRING	Tag: código de identificação técnica/local do ativo, no formato 9.999.9.9999 (ex.: 1.023.3.0346).	Texto de 12 a 13 caracteres; 7 valores vazios.	CSV: coluna tag (sem transformação).
tipo_manutencao	STRING	Tipo da ordem de manutenção (ex.: PREVENTIVA, INSPEÇÃO, CORRETIVA PLANEJADA).	16 categorias (ver dim_tipo_manutencao).	CSV: coluna tipo_manutencao (sem transformação).

MVP - Data Engineering Pipeline de Dados na Nuvem

data_manutencao	STRING	Data da manutenção registrada na OM, em texto dd/MM/yyyy. Em 74% das OMs fica a até 7 dias do início original.	Datas de 2022 a 2027 (a maioria em 2026); contém o valor inválido 28/04/0026.	CSV: coluna data_manutencao (sem transformação).
data_termino	STRING	Data de término (encerramento) da OM, em texto dd/MM/yyyy. Vazia quando a OM não foi terminada.	Vazia em 1.965 linhas (todas OMs não terminadas).	CSV: coluna data_termino (sem transformação).
data_inicio_original	STRING	Data de início originalmente prevista da OM, em texto dd/MM/yyyy.	01/01/2026 a 31/08/2026.	CSV: coluna data_inicio_original (sem transformação).
estado_om	STRING	Situação atual da OM.	Terminada, Suspensa, Não Iniciada, Iniciada.	CSV: coluna estado_om (sem transformação).
_rescued_data	STRING	Coluna criada automaticamente pelo Databricks: guarda dados que não couberam no formato esperado na leitura do CSV.	Esperado: sempre vazia (NULL).	Gerada pelo read_files.
_arquivo_origem	STRING	Metadado de controle: caminho do arquivo do qual a linha foi lida.	/Volumes/workspace/bronze/raw_files/om_manutencao_2026.csv	Metadado _metadata.file_path.
_ingerido_em	TIMESTAMP	Metadado de controle: data e hora da carga na Bronze.	Data/hora da execução do notebook 01.	current_timestamp() no notebook 01.

05 - CATÁLOGO DE DADOS (documentação no Unity Catalog)

Objetivo: registrar, dentro do próprio Databricks, uma descrição para cada **tabela** e cada **coluna**.

workspace.bronze.om_manutencao_raw (Bronze)

```

3
1 COMMENT ON TABLE workspace.bronze.om_manutencao_raw IS 'Ordens de manutenção (OM) de janeiro a agosto de 2026, exatamente como exportadas do sistema de gestão de manutenção. Nenhum
valor foi alterado; todas as colunas originais estão em texto. Granularidade: 1 linha por OM (25.872 linhas). Origem: arquivo om_manutencao_2026.csv, carregado no volume workspace.
bronze.raw_files.';
2
3 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.linha IS 'Número sequencial da linha no arquivo exportado. Domínio: Texto numérico de 1 a 25872. Linhagem: CSV: coluna linha (sem
transformação).';
4 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.ordem IS 'Número da ordem de manutenção (OM), identificador único da OM. Domínio: Texto numérico de 9 dígitos (100050417 a
300157661). Linhagem: CSV: coluna ordem (sem transformação).';
5 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.equipamento IS 'Código do equipamento: letras da classe + número (ex.: AUT114 = autoclave 114). O código PREDIAL representa
manutenção predial geral, sem equipamento específico. Domínio: Texto de 4 a 16 caracteres; pode ter minúsculas (problema tratado na Silver). Linhagem: CSV: coluna equipamento (sem
transformação).';
6 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.nome_equipamento IS 'Descrição textual do equipamento (ex.: AUTOCLAVE, CHILLER). Domínio: 656 nomes distintos. Linhagem: CSV:
coluna nome_equipamento (sem transformação).';
7 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.tag IS 'Tag: código de identificação técnica/local do ativo, no formato 9.999.9.9999 (ex.: 1.023.3.0346). Domínio: Texto de 12 a
13 caracteres; 7 valores vazios. Linhagem: CSV: coluna tag (sem transformação).';
8 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.tipo_manutencao IS 'Tipo da ordem de manutenção (ex.: PREVENTIVA, INSPEÇÃO, CORRETIVA PLANEJADA). Domínio: 16 categorias (ver
dim_tpo_manutencao). Linhagem: CSV: coluna tipo_manutencao (sem transformação).';
9 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.data_manutencao IS 'Data da manutenção registrada na OM, em texto dd/MM/yyyy. Em 74% das OMs fica a até 7 dias do início original.
Domínio: Datas de 2022 a 2027 (a maioria em 2026); contém o valor inválido 28/04/0026. Linhagem: CSV: coluna data_manutencao (sem transformação).';
10 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.data_termino IS 'Data de término (encerramento) da OM, em texto dd/MM/yyyy. Vazia quando a OM não foi terminada. Domínio: Vazia em
1.965 linhas (todas OMs não terminadas). Linhagem: CSV: coluna data_termino (sem transformação).';
11 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.data_inicio_original IS 'Data de início originalmente prevista da OM, em texto dd/MM/yyyy. Domínio: 01/01/2026 a 31/08/2026.
Linhagem: CSV: coluna data_inicio_original (sem transformação).';
12 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.estado_om IS 'Situação atual da OM. Domínio: Terminada, Suspensa, Não Iniciada, Iniciada. Linhagem: CSV: coluna estado_om (sem
transformação).';
13 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.rescued_data IS 'Coluna criada automaticamente pelo Databricks: guarda dados que não couberam no formato esperado na leitura do
CSV. Domínio: Esperado: sempre vazia (NULL). Linhagem: Gerada pelo read_files.';
14 COMMENT ON COLUMN workspace.bronze.om_manutencao_raw.arquivo_origem IS 'Metadado de controle: caminho do arquivo do qual a linha foi lida. Domínio: /Volumes/workspace/bronze/
raw_files/om_manutencao_2026.csv. Linhagem: Metadado _metadata.file_path.';

```

Figura 8 – Notebook 5: Catálogo de dados

MVP - Data Engineering

Pipeline de Dados na Nuvem

workspace.silver.om_manutencao (Silver)

Ordens de manutenção limpas: tipos corretos (datas como DATE), textos padronizados em maiúsculas, erro de ano corrigido e problemas de qualidade sinalizados em colunas flag_*. Granularidade: 1 linha por OM (25.872 linhas). Origem: workspace.bronze.om_manutencao_raw (notebook 03).

Tabela 4 – Descrição dos tipos de dados da camada silver

Coluna	Tipo	Descrição	Domínio	Linhagem
linha_origem	INT	Número da linha no arquivo original (rastreadibilidade).	1 a 25872.	bronze.om_manutencao_raw.linha via try_cast INT (T1).
ordem	BIGINT	Número da ordem de manutenção (OM). Chave primária: única em toda a tabela.	100050417 a 300157661; sem duplicatas.	bronze.om_manutencao_raw.ordem via try_cast BIGINT (T1).
equipamento	STRING	Código do equipamento em maiúsculas (ex.: AUT114). PREDIAL = manutenção predial geral.	7.221 códigos distintos.	bronze.om_manutencao_raw.equipamento com UPPER(TRIM) (T2).
nome_equipamento	STRING	Descrição do equipamento em maiúsculas.	656 nomes distintos.	bronze.om_manutencao_raw.nome_equipamento com UPPER(TRIM) (T2).
tag	STRING	Tag (código técnico/local) em maiúsculas. NULL quando ausente.	1.585 tags distintas; 7 NULL.	bronze.om_manutencao_raw.tag com UPPER(TRIM), vazio vira NULL (T2, T3).
tipo_manutencao	STRING	Tipo da OM em maiúsculas.	16 categorias.	bronze.om_manutencao_raw.tipo_manutencao com UPPER(TRIM) (T2).

MVP - Data Engineering

Pipeline de Dados na Nuvem

estado_om	STRING	Situação da OM em maiúsculas.	TERMINADA, SUSPENSA, NÃO INICIADA, INICIADA.	bronze.om_manutencao_raw.estado_om com UPPER(TRIM) (T2).
data_manutencao	DATE	Data da manutenção registrada na OM.	2022-11-28 a 2027-08-23 (461 fora de 2026 sinalizadas).	bronze.om_manutencao_raw.data_manutencao: correção do ano 00xx e conversão dd/MM/yyyy para DATE (T4, T5).
data_termino	DATE	Data de término da OM. NULL quando a OM não foi terminada.	2023-03-15 a 2026-09-04; 1.965 NULL (OMs não terminadas).	bronze.om_manutencao_raw.data_termino: correção do ano e conversão para DATE (T4, T5).
data_inicio_original	DATE	Data de início originalmente prevista da OM. É a data de referência das análises.	2026-01-01 a 2026-08-31.	bronze.om_manutencao_raw.data_inicio_original: conversão para DATE (T5).
duracao_dias	INT	Dias entre início original e término. Calculada só para OM TERMINADA com datas coerentes; caso contrário NULL.	0 a 217; 23.238 preenchidas.	datediff(data_termino, data_inicio_original) (T7).
classe Equipamento	STRING	Classe do equipamento: letras iniciais do código (AUT, CHI, ARS...).	225 classes.	regexp_extract(equipamento, letras iniciais) (T8).
mes_referencia	DATE	Primeiro dia do mês do início original.	2026-01-01 a 2026-08-01 (8 meses).	trunc(data_inicio_original, MM) (T9).
flag_ano_corrigido	BOOLEAN	Verdadeiro se alguma data teve o ano inválido (00xx) corrigido para 20xx.	true em 1 linha.	Comparação regex sobre datas da Bronze (T4/T6).
flag_termino_antes_inicio	BOOLEAN	Verdadeiro se data_termino é anterior a data_inicio_original (inconsistência). Essas OMs ficam sem duracao_dias.	true em 669 linhas.	data_termino < data_inicio_original (T6).

MVP - Data Engineering Pipeline de Dados na Nuvem

workspace.silver.om_manutencao (Silver)

```

1 COMMENT ON TABLE workspace.silver.om_manutencao IS 'Ordens de manutenção limpas: tipos corretos (datas como DATE), textos padronizados em maiúsculas, erro de ano corrigido e problemas de qualidade sinalizados em colunas flag_*'. Granularidade: 1 linha por OM (25.872 linhas). Origem: workspace.bronze.om_manutencao_raw (notebook 03).';
2
3 COMMENT ON COLUMN workspace.silver.om_manutencao.linha_origem IS 'Número da linha no arquivo original (rastreadibilidade). Domínio: 1 a 25872. Linhagem: bronze.om_manutencao_raw.linha via try_cast INT (T1).';
4 COMMENT ON COLUMN workspace.silver.om_manutencao.ordem IS 'Número da ordem de manutenção (OM). Chave primária: única em toda a tabela. Domínio: 100050417 a 300157661; sem duplicatas. Linhagem: bronze.om_manutencao_raw.ordem via try_cast BIGINT (T1).';
5 COMMENT ON COLUMN workspace.silver.om_manutencao.equipamento IS 'Código do equipamento em maiúsculas (ex.: AUT114). PREDIAL = manutenção predial geral. Domínio: 7.221 códigos distintos. Linhagem: bronze.om_manutencao_raw.equipamento com UPPER(TRIM) (T2).';
6 COMMENT ON COLUMN workspace.silver.om_manutencao.nome_equipamento IS 'Descrição do equipamento em maiúsculas. Domínio: 656 nomes distintos. Linhagem: bronze.om_manutencao_raw.nome_equipamento com UPPER(TRIM) (T2).';
7 COMMENT ON COLUMN workspace.silver.om_manutencao.tag IS 'Tag (código técnico/local) em maiúsculas. NULL quando ausente. Domínio: 1.585 tags distintas; 7 NULL. Linhagem: bronze.om_manutencao_raw.tag com UPPER(TRIM), vazio vira NULL (T2, T3).';
8 COMMENT ON COLUMN workspace.silver.om_manutencao.tipo_manutencao IS 'Tipo da OM em maiúsculas. Domínio: 16 categorias. Linhagem: bronze.om_manutencao_raw.tipo_manutencao com UPPER(TRIM) (T2).';
9 COMMENT ON COLUMN workspace.silver.om_manutencao.estado_om IS 'Situação da OM em maiúsculas. Domínio: TERMINADA, SUSPensa, NÃO INICIADA, INICIADA. Linhagem: bronze.om_manutencao_raw.estado_om com UPPER(TRIM) (T2).';
10 COMMENT ON COLUMN workspace.silver.om_manutencao.data_manutencao IS 'Data da manutenção registrada na OM. Domínio: 2022-11-28 a 2027-08-23 (461 fora de 2026 sinalizadas). Linhagem: bronze.om_manutencao_raw.data_manutencao: correção do ano 00xx e conversão dd/MM/yyyy para DATE (T4, T5).';
11 COMMENT ON COLUMN workspace.silver.om_manutencao.data_termino IS 'Data de término da OM. NULL quando a OM não foi terminada. Domínio: 2023-03-15 a 2026-09-04; 1.965 NULL (OMs não terminadas). Linhagem: bronze.om_manutencao_raw.data_termino: correção do ano e conversão para DATE (T4, T5).';
12 COMMENT ON COLUMN workspace.silver.om_manutencao.data_inicio_original IS 'Data de início originalmente prevista da OM. É a data de referência das análises. Domínio: 2026-01-01 a 2026-08-31. Linhagem: bronze.om_manutencao_raw.data_inicio_original: conversão para DATE (T5).';
13 COMMENT ON COLUMN workspace.silver.om_manutencao.duracao_dias IS 'Dias entre início original e término. Calculada só para OM TERMINADA com datas coerentes; caso contrário NULL. Domínio: 0 a 217; 23.238 preenchidas. Linhagem: datediff(data_termino, data_inicio_original) (T7).';
14 COMMENT ON COLUMN workspace.silver.om_manutencao.classe_equipamento IS 'Classe do equipamento: letras iniciais do código (AUT, CHI, ARS...). Domínio: 225 classes. Linhagem: regexp_extract(equipamento, letras_iniciais) (T8).';
15 COMMENT ON COLUMN workspace.silver.om_manutencao.mes_referencia IS 'Primeiro dia do mês do início original. Domínio: 2026-01-01 a 2026-08-01 (8 meses). Linhagem: trunc(data_inicio_original, MM) (T9).';
16 COMMENT ON COLUMN workspace.silver.om_manutencao.flag_ano_corrigido IS 'Verdadeiro se alguma data teve o ano inválido (00xx) corrigido para 20xx. Domínio: true em 1 linha. Linhagem: Comparação regex sobre datas da Bronze (T4/T6).';
17 COMMENT ON COLUMN workspace.silver.om_manutencao.flag_termino_antes_inicio IS 'Verdadeiro se data_termino é anterior a data_inicio_original (inconsistência). Essas OMs ficam sem duracao_dias. Domínio: true em 669 linhas. Linhagem: data_termino < data_inicio_original (T6).';
18 COMMENT ON COLUMN workspace.silver.om_manutencao.flag_manutencao_fora_2026 IS 'Verdadeiro se o ano de data_manutencao não é 2026 (suspeita de erro de digitação do ano). Domínio: true em 461 linhas. Linhagem: year(data_manutencao) <> 2026 (T6).';
19 COMMENT ON COLUMN workspace.silver.om_manutencao.flag_tag_ausente IS 'Verdadeiro se a OM não tem tag. Domínio: true em 7 linhas. Linhagem: tag IS NULL (T6).';
20 COMMENT ON COLUMN workspace.silver.om_manutencao.lingerido_em IS 'Data/hora da carga na Bronze (herdada). Domínio: Data/hora da execução do notebook 01. Linhagem: bronze.om_manutencao_raw.lingerido_em';

```

Figura 9 – Notebook 5: Catálogo de dados

workspace.gold.dim_equipamento (Gold)

Dimensão de equipamentos do esquema estrela. Granularidade: 1 linha por código de equipamento (7.221 linhas). Origem: workspace.silver.om_manutencao (notebook 04).

Tabela 5 – Descrição dos tipos de dados da tabela dimensão equipamentos na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
cod_equipamento	STRING	Código do equipamento (chave da dimensão).	7.221 valores únicos.	silver.om_manutencao.equipamento.
nome_equipamento	STRING	Descrição do equipamento.	656 nomes distintos.	silver.om_manutencao.nome_equipamento (MAX por código).
classe_equipamento	STRING	Classe do equipamento (letras iniciais do código).	225 classes.	silver.om_manutencao.classe_equipamento.
nome_classe	STRING	Nome legível da classe: o nome de equipamento mais frequente dentro da classe (ex.: AUT = AUTOCLAVE).	225 valores.	Calculado com ROW_NUMBER sobre a frequência de nomes por classe.

workspace.gold.dim_equipamento (Gold)

```

1 COMMENT ON TABLE workspace.gold.dim_equipamento IS 'Dimensão de equipamentos do esquema estrela. Granularidade: 1 linha por código de equipamento (7.221 linhas). Origem: workspace.silver.om_manutencao (notebook 04).';
2
3 COMMENT ON COLUMN workspace.gold.dim_equipamento.cod_equipamento IS 'Código do equipamento (chave da dimensão). Domínio: 7.221 valores únicos. Linhagem: silver.om_manutencao.equipamento.';
4 COMMENT ON COLUMN workspace.gold.dim_equipamento.nome_equipamento IS 'Descrição do equipamento. Domínio: 656 nomes distintos. Linhagem: silver.om_manutencao.nome_equipamento (MAX por código).';
5 COMMENT ON COLUMN workspace.gold.dim_equipamento.classe_equipamento IS 'Classe do equipamento (letras iniciais do código). Domínio: 225 classes. Linhagem: silver.om_manutencao.classe_equipamento.';
6 COMMENT ON COLUMN workspace.gold.dim_equipamento.nome_classe IS 'Nome legível da classe: o nome de equipamento mais frequente dentro da classe (ex.: AUT = AUTOCLAVE). Domínio: 225 valores. Linhagem: Calculado com ROW_NUMBER sobre a frequência de nomes por classe.';

```

Figura 10 – Notebook 5: Catálogo de dados

MVP - Data Engineering

Pipeline de Dados na Nuvem

workspace.gold.dim_tipo_manutencao (Gold)

Dimensão de tipos de manutenção com agrupamento de negócio. Granularidade: 1 linha por tipo (16 linhas). Origem: tabela de mapeamento definida no notebook 04.

Tabela 6 – Descrição dos tipos de dados da tabela dimensão tipo de manutenção na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
tipo_manutencao	STRING	Tipo da ordem de manutenção (chave da dimensão).	16 valores únicos.	silver.om_manutencao.tipo_manutencao.
grupo_manutencao	STRING	Grupo de negócio do tipo: PREVENTIVA/INSPEÇÃO, CORRETIVA, PROJETOS/MELHORIAS ou APOIO/ADMINISTRATIVO.	4 grupos.	Mapeamento manual definido no notebook 04 (decisão de modelagem).



workspace.gold.dim_tipo_manutencao (Gold)

```

1 COMMENT ON TABLE workspace.gold.dim_tipo_manutencao IS 'Dimensão de tipos de manutenção com agrupamento de negócio. Granularidade: 1 linha por tipo (16 linhas). Origem: tabela de
  mapeamento definida no notebook 04.';
2
3 COMMENT ON COLUMN workspace.gold.dim_tipo_manutencao.tipo_manutencao IS 'Tipo da ordem de manutenção (chave da dimensão). Domínio: 16 valores únicos. Linhagem: silver.om_manutencao.
  tipo_manutencao.';
4 COMMENT ON COLUMN workspace.gold.dim_tipo_manutencao.grupo_manutencao IS 'Grupo de negócio do tipo: PREVENTIVA/INSPEÇÃO, CORRETIVA, PROJETOS/MELHORIAS ou APOIO/ADMINISTRATIVO.
  Domínio: 4 grupos. Linhagem: Mapeamento manual definido no notebook 04 (decisão de modelagem).';

```

See performance (3) Checked for improvements

Figura 11 – Notebook 5: Catálogo de dados

workspace.gold.dim_data (Gold)

Dimensão calendário. Granularidade: 1 linha por dia, de 01/01/2026 a 31/12/2027 (730 linhas). Gerada por código, sem fonte externa.

Tabela 7 – Descrição dos tipos de dados da tabela dimensão data na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
data	DATE	Dia do calendário (chave da dimensão).	2026-01-01 a 2027-12-31.	sequence() no notebook 04.
ano	INT	Ano.	2026 ou 2027.	year(data).
mes	INT	Número do mês.	1 a 12.	month(data).
nome_mes	STRING	Nome do mês em português.	Janeiro a Dezembro.	Derivado de month(data).
ano_mes	STRING	Ano e mês no formato yyyy-MM (útil para ordenar gráficos).	2026-01 a 2027-12.	date_format(data, yyyy-MM).
trimestre	INT	Trimestre do ano.	1 a 4.	quarter(data).
dia_semana	STRING	Nome do dia da semana em português.	Domingo a Sábado.	Derivado de dayofweek(data).

MVP - Data Engineering Pipeline de Dados na Nuvem

workspace.gold.dim_data (Gold)

```

1 COMMENT ON TABLE workspace.gold.dim_data IS 'Dimensão calendário. Granularidade: 1 linha por dia, de 01/01/2026 a 31/12/2027 (730 linhas). Gerada por código, sem fonte externa.';
2
3 COMMENT ON COLUMN workspace.gold.dim_data.data IS 'Dia do calendário (chave da dimensão). Domínio: 2026-01-01 a 2027-12-31. Linhagem: sequence() no notebook 04.';
4 COMMENT ON COLUMN workspace.gold.dim_data.ano IS 'Ano. Domínio: 2026 ou 2027. Linhagem: year(data).';
5 COMMENT ON COLUMN workspace.gold.dim_data.mes IS 'Número do mês. Domínio: 1 a 12. Linhagem: month(data).';
6 COMMENT ON COLUMN workspace.gold.dim_data.nome_mes IS 'Nome do mês em português. Domínio: Janeiro a Dezembro. Linhagem: Derivado de month(data).';
7 COMMENT ON COLUMN workspace.gold.dim_data.ano_mes IS 'Ano e mês no formato yyyy-MM (útil para ordenar gráficos). Domínio: 2026-01 a 2027-12. Linhagem: date_format(data, yyyy-MM).';
8 COMMENT ON COLUMN workspace.gold.dim_data.trimestre IS 'Trimestre do ano. Domínio: 1 a 4. Linhagem: quarter(data).';
9 COMMENT ON COLUMN workspace.gold.dim_data.dia_semana IS 'Nome do dia da semana em português. Domínio: Domingo a Sábado. Linhagem: Derivado de dayofweek(data).';

```

See performance (8) Checked for improvements

Figura 12 – Notebook 5: Catálogo de dados

workspace.gold.fato_ordem_manutencao (Gold)

Tabela fato do esquema estrela. Granularidade: 1 linha por ordem de manutenção (25.872 linhas). Relaciona-se com dim_equipamento (cod_equipamento), dim_tipo_manutencao (tipo_manutencao) e dim_data (data_inicio_original). Origem: workspace.silver.om_manutencao (notebook 04).

Tabela 8 – Descrição dos tipos de dados da tabela fato na camada gold

Coluna	Tipo	Descrição	Domínio	Linhagem
ordem	BIGINT	Número da OM (chave da fato).	Único; 100050417 a 300157661.	silver.om_manutencao.ordem.
cod_equipamento	STRING	Chave estrangeira para dim_equipamento.	7.221 valores.	silver.om_manutencao.cod_equipamento.
tipo_manutencao	STRING	Chave estrangeira para dim_tipo_manutencao.	16 valores.	silver.om_manutencao.tipo_manutencao.
data_inicio_original	DATE	Chave estrangeira para dim_data; data de referência das análises.	2026-01-01 a 2026-08-31.	silver.om_manutencao.data_inicio_original.
tag_local	STRING	Tag (código técnico/local) da OM. Fica na fato porque um equipamento pode ter mais de uma tag.	1.585 tags; 7 NULL.	silver.om_manutencao.tag_local.
estado_om	STRING	Situação da OM.	TERMINADA, SUSPensa, NÃO INICIADA, INICIADA.	silver.om_manutencao.estado_om.
data_manutencao	DATE	Data da manutenção registrada na OM.	2022-11-28 a 2027-08-23.	silver.om_manutencao.data_manutencao.
data_termino	DATE	Data de término da OM; NULL se não terminada.	2023-03-15 a 2026-09-04.	silver.om_manutencao.data_termino.
duracao_dias	INT	Medida: dias de execução (término - início original). NULL se não aplicável.	0 a 217.	silver.om_manutencao.duracao_dias.
flag_ano_corrigido	BOOLEAN	Sinalizador: ano de data corrigido.	1 linha true.	silver.om_manutencao.flag_ano_corrigido.
flag_termino_antes_inicio	BOOLEAN	Sinalizador: término anterior ao início.	669 linhas true.	silver.om_manutencao.flag_termino_antes_inicio.
flag_manutencao_fora_2026	BOOLEAN	Sinalizador: data_manutencao fora de 2026.	461 linhas true.	silver.om_manutencao.flag_manutencao_fora_2026.
flag_tag_ausente	BOOLEAN	Sinalizador: OM sem tag.	7 linhas true.	silver.om_manutencao.flag_tag_ausente.

MVP - Data Engineering Pipeline de Dados na Nuvem

```
workspace.gold.fato_ordem_manutencao (Gold)

1 COMMENT ON TABLE workspace.gold.fato_ordem_manutencao IS 'Tabela fato do esquema estrela. Granularidade: 1 linha por ordem de manutenção (25.872 linhas). Relaciona-se com
dim_equipamento (cod_equipamento), dim_tipo_manutencao (tipo_manutencao) e dim_data (data_inicio_original). Origem: workspace.silver.om_manutencao (notebook 04).';
2
3 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.ordem IS 'Número da OM (chave de fato). Domínio: Único; 100050417 a 300157661. Linhagem: silver.om_manutencao.ordem.';
4 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.cod_equipamento IS 'Chave estrangeira para dim_equipamento. Domínio: 7.221 valores. Linhagem: silver.om_manutencao.equipamento.';
5 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.tipo_manutencao IS 'Chave estrangeira para dim_tipo_manutencao. Domínio: 16 valores. Linhagem: silver.om_manutencao.
tipo_manutencao.';
6 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.data_inicio_original IS 'Chave estrangeira para dim_data; data de referência das análises. Domínio: 2026-01-01 a 2026-08-31.
Linhagem: silver.om_manutencao.data_inicio_original.';
7 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.tag_local IS 'Tag (código técnico/local) da OM. Fica na fato porque um equipamento pode ter mais de uma tag. Domínio: 1.585
tags; 7 NULL. Linhagem: silver.om_manutencao.tag.';
8 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.estado_om IS 'Situação da OM. Domínio: TERMINADA, SUSPensa, NÃO INICIADA, INICIADA. Linhagem: silver.om_manutencao.estado_om.';
9 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.data_manutencao IS 'Data da manutenção registrada na OM. Domínio: 2022-11-28 a 2027-08-23. Linhagem: silver.om_manutencao.
data_manutencao.';
10 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.data_termino IS 'Data de término da OM; NULL se não terminada. Domínio: 2023-03-15 a 2026-09-04. Linhagem: silver.om_manutencao.
data_termino.';
11 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.duracao_dias IS 'Medida: dias de execução (término - início original). NULL se não aplicável. Domínio: 0 a 217. Linhagem: silver.
om_manutencao.duracao_dias.';
12 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.flag_ano_corrigido IS 'Sinalizador: ano de data corrigido. Domínio: 1 linha true. Linhagem: silver.om_manutencao.
flag_ano_corrigido.';
13 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.flag_termino_antes_inicio IS 'Sinalizador: término anterior ao início. Domínio: 669 linhas true. Linhagem: silver.om_manutencao.
flag_termino_antes_inicio.';
14 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.flag_manutencao_fora_2026 IS 'Sinalizador: data_manutencao fora de 2026. Domínio: 461 linhas true. Linhagem: silver.
om_manutencao.flag_manutencao_fora_2026.';
15 COMMENT ON COLUMN workspace.gold.fato_ordem_manutencao.flag_tag_ausente IS 'Sinalizador: OM sem tag. Domínio: 7 linhas true. Linhagem: silver.om_manutencao.flag_tag_ausente.';

> See performance (14) ✓ Checked for improvements
```

Figura 14 – Notebook 5: Catálogo de dados

Pipeline de Dados (Etapa 4.4)

Organização do ETL

O pipeline segue a **Arquitetura Medalhão**: dado bruto (Bronze), dado limpo (Silver) e dado pronto para consumo (Gold). O processo foi **ramificado em notebooks separados** para facilitar a manutenção e organização fluxo de processo, todos em SQL para execução em sequência na computação serverless do Databricks. Caso seja necessário a mudança da regra de limpeza, é possível alterar apenas o notebook 03 e a reexecução dos demais notebooks.

Tabela 9 – Descrição dos notebooks e organização das camadas

Fluxo	Notebook	O que faz	Tabela resultante
Extract + Load	01_bronze_ingestao	Lê o CSV do volume e grava sem alterar valores	bronze.om_manutencao_raw
Diagnóstico	02_qualidade_diagnostico	Mede problemas (não altera dados)	(consultas)
Transform	03_silver_limpeza	Tipagem, padronização, correções e sinalizações	silver.om_manutencao
Load (modelo)	04_gold_modelagem	Cria fato e dimensões (esquema estrela)	gold.fato_ordem_manutencao , dim_equipamento, dim_tipo_manutencao, dim_data
Documentação	05_catalogo_dados	Descrições de tabelas/colunas no Unity Catalog	(metadados)
Consumo	06_analise_perguntas	Responde às 5 perguntas de negócio	(consultas)

MVP - Data Engineering

Pipeline de Dados na Nuvem

Transformações Realizadas (Silver)

Tabela 10 – Descrição das transformações realizadas na camada silver

#	Transformação	Por que foi feita	Impacto nos dados
T1	Conversão de linha e ordem para número (try_cast)	Identificadores estavam como texto	Tipos INT e BIGINT
T2	UPPER(TRIM()) em textos	"predial" e "PREDIAL" eram contados como equipamentos diferentes	7.608 para 7.221 códigos de equipamento
T3	Texto vazio vira NULL	Vazio e NULL significam "sem valor"	Ausência padronizada
T4	Correção do ano 00xx para 20xx	28/04/0026 é erro de digitação (início em 17/04/2026)	1 linha corrigida e sinalizada
T5	Conversão de texto dd/MM/yyyy para DATE	Permite cálculos e ordenação correta	3 colunas de data tipadas
T6	Colunas flag_* de qualidade	Problemas duvidosos são sinalizados, não apagados	669 / 461 / 7 / 1 linhas sinalizadas
T7	duracao_dias = término - início	Métrica da pergunta 4; só OM terminada e coerente	23.238 OMs com duração
T8	classe_equipamento (letras iniciais do código)	Agrupar equipamentos do mesmo tipo	225 classes
T9	mes_referencia (mês do início original)	Facilitar análises mensais	8 meses
T10	Deduplicação por ordem (QUALIFY ROW_NUMBER)	Garantir 1 linha por OM em cargas futuras	0 duplicatas removidas hoje

Reprodutibilidade: todas as tabelas são criadas com CREATE OR REPLACE TABLE, portanto reexecutar a sequência de notebooks com um arquivo novo refaz o pipeline sozinho, sem duplicar dados. Nenhuma linha foi excluída ao longo do pipeline: Bronze, Silver e a fato têm o mesmo total (25.872).

Evidências de persistência e validação





Figura 15 – Notebook 03: Validação da Silver: mesma contagem da Bronze (V1)

MVP - Data Engineering

Pipeline de Dados na Nuvem



00_setup_ambiente 01_bronze_ingestao 02_qualidade_diagnostico 03_silver_limpeza x 04_gold_modelagem

File Edit View Run Help SQL Full Last edit was 52 minutes ago

05:20 PM (3s) 7

```

1 -- V4: contagem de cada sinalização de qualidade
2 SELECT
3   SUM(CASE WHEN flag_ano_corrigido THEN 1 ELSE 0 END) AS ano_corrigido, -- esperado 1
4   SUM(CASE WHEN flag_termino_antes_inicio THEN 1 ELSE 0 END) AS termino_antes_inicio, -- esperado 669
5   SUM(CASE WHEN flag_manutencao_fora_2026 THEN 1 ELSE 0 END) AS manutencao_fora_2026, -- esperado 461
6   SUM(CASE WHEN flag_tag_ausente THEN 1 ELSE 0 END) AS tag_ausente, -- esperado 7
7   SUM(CASE WHEN duracao_dias IS NOT NULL THEN 1 ELSE 0 END) AS oms_com_duracao -- esperado 23238
8 FROM workspace.silver.om_manutencao;


```

See performance (1) ✓ Checked for improvements

	ano_corrigido	termino_antes_inicio	manutencao_fora_2026	tag_ausente	oms_com_duracao
1	1	669	461	7	23238

1 row 2.577s runtime Refreshed 51m ago

Figura 16 – Notebook 03: Contagem de sinalizações de qualidade (V4).



00_setup_ambiente 01_bronze_ingestao 02_qualidade_diagnostico 03_silver_limpeza 04_gold_modelagem x

File Edit View Run Help SQL Full Last edit was now

Just now (6s) 16

```

1 SELECT 'G1 - linhas Bronze' AS verificacao, COUNT(*) AS resultado FROM workspace.bronze.om_manutencao_raw
2 UNION ALL SELECT 'G1 - linhas Silver', COUNT(*) FROM workspace.silver.om_manutencao
3 UNION ALL SELECT 'G1 - linhas fato (Gold)', COUNT(*) FROM workspace.gold.fato_ordem_manutencao
4 UNION ALL SELECT 'G2 - OMs sem equipamento', COUNT(*) FROM workspace.gold.fato_ordem_manutencao f LEFT JOIN workspace.gold.dim_equipamento e ON f.
   cod_equipamento = e.cod_equipamento WHERE e.cod_equipamento IS NULL
5 UNION ALL SELECT 'G2 - OMs sem tipo', COUNT(*) FROM workspace.gold.fato_ordem_manutencao f LEFT JOIN workspace.gold.dim_tipo_manutencao t ON f.
   tipo_manutencao = t.tipo_manutencao WHERE t.tipo_manutencao IS NULL
6 UNION ALL SELECT 'G2 - OMs sem data', COUNT(*) FROM workspace.gold.fato_ordem_manutencao f LEFT JOIN workspace.gold.dim_data d ON f.
   data_inicio_original = d.data WHERE d.data IS NULL
7 UNION ALL SELECT 'G4 - linhas dim_equipamento', COUNT(*) FROM workspace.gold.dim_equipamento
8 UNION ALL SELECT 'G4 - linhas dim_tipo_manutencao', COUNT(*) FROM workspace.gold.dim_tipo_manutencao
9 UNION ALL SELECT 'G4 - linhas dim_data', COUNT(*) FROM workspace.gold.dim_data;

```

See performance (1) ✓ Checked for improvements

	verificacao	resultado
1	G2 - OMs sem equipamento	0
2	G2 - OMs sem tipo	0
3	G2 - OMs sem data	0
4	G1 - linhas Bronze	25872
5	G1 - linhas Silver	25872
6	G1 - linhas fato (Gold)	25872
7	G4 - linhas dim_equipamento	7221
8	G4 - linhas dim_tipo_manutenc...	16
9	G4 - linhas dim_data	730

9 rows 5.617s runtime Refreshed Now

Figura 17 – Notebook 04: Validação da Gold, reconciliação de volumes (bronze = silver = fato = 25.872), integridade referencial e tamanho das tabelas.

Qualidade de Dados (Etapa 4.5)

A qualidade foi avaliada **para cada atributo** do conjunto de dados, na camada Bronze (notebook 02), considerando as cinco dimensões pedidas: completude, consistência, unicidade, acurácia e outliers. Os tratamentos foram aplicados na Silver (notebook 03) e verificados por consultas de validação. Onde o problema não pôde ser corrigido com certeza, o registro foi **mantido e sinalizado**, e não apagado.

Problemas detectados e como foram resolvidos

Tabela 11 – resumo dos problemas detectados e resolvidos na camada silver

#	Dimensão	Problema detectado	Qtd	Tratamento
1	Completude	data_termino vazia	1.965	Mantido como NULL: 100% são OMs não terminadas (Suspensa, Não Iniciada, Iniciada). Comportamento esperado, não é erro.
2	Completude	tag vazia	7	Mantido NULL + flag_tag_ausente
3	Consistência	Ano impossível (28/04/0026)	1 linha (2 campos)	Corrigido para 2026 + flag_ano_corrigido
4	Consistência	Datas armazenadas como texto	todas	Convertidas para DATE (formato dd/MM/yyyy validado: 0 fora do padrão)
5	Consistência	Caixa alta/baixa inconsistente (predial, Predial, PREDIAL, lvr001...)	equipamento 1.006; nome 19; tag 29	UPPER(TRIM) em todos os textos; 7.608 códigos viram 7.221
6	Consistência	Variações no formato da tag (6 formatos; dominante 9.999.9.9999)	127 fora do dominante	Mantidas: são códigos técnicos plausíveis (só padronizadas em maiúsculas)
7	Unicidade	Duplicatas de OM	0	Nenhuma ação; deduplicação por ordem mantida no ETL
8	Unicidade	Equipamento com mais de uma tag	181	Tag mantida na tabela fato (decisão de modelagem)
9	Acurácia	Término anterior ao início (frequentemente só o ano parece errado)	669 (2,8% das terminadas)	Mantidas + flag_termino_antes_inicio; excluídas do cálculo de duração
10	Acurácia	data_manutencao fora de 2026 (2022 a 2025 e 2027)	461	Mantidas + flag_manutencao_fora_2026; não usadas como data de referência
11	Outliers	Duração acima do limite IQR (28,5 dias)	1.424 (6,1%)	Mantidos (manutenções longas são reais); análises usam mediana ao lado da média

MVP - Data Engineering

Pipeline de Dados na Nuvem

Evidências: Completeude




Figura 18 – Notebook 02: Evidências de Completeude - contagem de vazios por coluna, e vazios de data_termino por estado da OM.

Evidências: Consistência

2. CONSISTÊNCIA - formato e padronização

```

1 SELECT 'data_manutencao' AS coluna,
2       SUM(CASE WHEN data_manutencao IS NOT NULL AND NOT data_manutencao RLIKE '[0-9]{2}/[0-9]{2}/[0-9]{4}$' THEN 1 ELSE 0 END) AS fora_do_formato,
3       SUM(CASE WHEN data_manutencao RLIKE '/00[0-9]{2}$' THEN 1 ELSE 0 END) AS ano_impossivel_00xx
4 FROM workspace.bronze.om_manutencao_raw
5
6 UNION ALL
7
8 SELECT 'data_termino',
9       SUM(CASE WHEN data_termino IS NOT NULL AND NOT data_termino RLIKE '[0-9]{2}/[0-9]{2}/[0-9]{4}$' THEN 1 ELSE 0 END),
10      SUM(CASE WHEN data_termino RLIKE '/00[0-9]{2}$' THEN 1 ELSE 0 END)
11 FROM workspace.bronze.om_manutencao_raw
12
13 UNION ALL
14
15 SELECT 'data_inicio_original',
16       SUM(CASE WHEN data_inicio_original IS NOT NULL AND NOT data_inicio_original RLIKE '[0-9]{2}/[0-9]{2}/[0-9]{4}$' THEN 1 ELSE 0 END),
17       SUM(CASE WHEN data_inicio_original RLIKE '/00[0-9]{2}$' THEN 1 ELSE 0 END)
18 FROM workspace.bronze.om_manutencao_raw;

```

See performance (l) ✓ Checked for improvements

coluna	fora_do_formato	ano_impossivel_00xx
data_manutencao	0	1
data_termino	0	1
data_inicio_origi...	0	0

```

1 SELECT linha, ordem, equipamento, tipo_manutencao, data_manutencao, data_termino, data_inicio_original
2 FROM workspace.bronze.om_manutencao_raw
3 WHERE data_manutencao RLIKE '/00[0-9]{2}$' OR data_termino RLIKE '/00[0-9]{2}$' OR data_inicio_original RLIKE '/00[0-9]{2}$';

```

See performance (l) ✓ Checked for improvements

linha	ordem	equipamento	tipo_manutencao	data_manutencao	data_termino	data_inicio_original
1	300144284	W184	PREVENTIVA	28/04/2026	28/04/2026	17/04/2026

```

1 SELECT 'equipamento' AS coluna,
2       SUM(CASE WHEN equipamento <> upper(trim(equipamento)) THEN 1 ELSE 0 END) AS linhas_com_caixa_inconsistente,
3       COUNT(DISTINCT equipamento) AS distintos_original,
4       COUNT(DISTINCT upper(trim(equipamento))) AS distintos_padronizado
5 FROM workspace.bronze.om_manutencao_raw
6
7 UNION ALL
8
9 SELECT 'nome_equipamento',
10      SUM(CASE WHEN nome_equipamento <> upper(trim(nome_equipamento)) THEN 1 ELSE 0 END),
11      COUNT(DISTINCT nome_equipamento),
12      COUNT(DISTINCT upper(trim(nome_equipamento)))
13 FROM workspace.bronze.om_manutencao_raw
14
15 UNION ALL
16
17 SELECT 'tag',
18       SUM(CASE WHEN tag <> upper(trim(tag)) THEN 1 ELSE 0 END),
19       COUNT(DISTINCT tag),
20       COUNT(DISTINCT upper(trim(tag)))
21 FROM workspace.bronze.om_manutencao_raw;

```

See performance (l) ✓ Checked for improvements

coluna	linhas_com_caixa_inconsistente	distintos_original	distintos_padronizado
equipamento	1006	7608	7221
nome_equipamen...	19	656	656
tag	29	1591	1585

MVP - Data Engineering

Pipeline de Dados na Nuvem

08:17 PM (3)

10

SQL

```

1 SELECT equipamento, COUNT(*) AS qtd
2 FROM workspace.bronze.om_manutencao_raw
3 WHERE equipamento <> upper(equipamento)
4 GROUP BY equipamento
5 ORDER BY qtd DESC
6 LIMIT 10;

```

See performance (1)

Checked for improvements

Table

+

	equipamento	qtd
1	predial	245
2	Predial	85
3	hr001	14
4	slp099	9
5	hr068	8
6	aut007	8
7	env001	5
8	env006	5
9	rev005	4
10	sws028	4

10 rows 2.945s runtime

Refreshed 11m ago

08:17 PM (3)

11

SQL

```

1 SELECT 'tipo_manutencao' AS coluna, tipo_manutencao AS valor, COUNT(*) AS qtd FROM workspace.bronze.om_manutencao_raw GROUP BY tipo_manutencao
2 UNION ALL
3 SELECT 'estado_om', estado_om, COUNT(*) FROM workspace.bronze.om_manutencao_raw GROUP BY estado_om
4 ORDER BY coluna, qtd DESC;

```

See performance (1)

Checked for improvements

Table

+

	coluna	valor	qtd
1	estado_om	Terminada	23907
2	estado_om	Suspensa	1031
3	estado_om	Não Iniciada	665
4	estado_om	Iniciada	269
5	tipo_manutenc...	CORRETIVA PLANEJADA	8246
6	tipo_manutenc...	PREVENTIVA	7333
7	tipo_manutenc...	INSPEÇÃO	5460
8	tipo_manutenc...	CORRETIVA EMERGENCIAL	1240
9	tipo_manutenc...	ADMINISTRAÇÃO DE USUÁRIOS	1066
10	tipo_manutenc...	APOIO OPERACIONAL	678
11	tipo_manutenc...	ROTEIRO DE INSPEÇÃO	560
12	tipo_manutenc...	MODIFICAÇÃO/MELHORIA	456
13	tipo_manutenc...	LUBRIFICAÇÃO	258
14	tipo_manutenc...	COMISSIONAMENTO/DESCOMISSONAMENTO	181
15	tipo_manutenc...	APOIO A PROJETOS	181

20 rows 3.190s runtime

Refreshed 11m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

08:17 PM (3)

12

SQL

```

1 SELECT
2 SUM(CASE WHEN NOT ordem REGEXP '[0-9]{9}$' THEN 1 ELSE 0 END) AS ordem_fora_do_padrao_9_digitos
3 FROM workspace.bronze.om_manutencao_raw;

```

See performance (1)

Checked for improvements

Table

+

	ordem_fora_do_padrao_9_digitos
1	0


1 row 2.969s runtime

Refreshed 11m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

MVP - Data Engineering

Pipeline de Dados na Nuvem



```

1 SELECT
2   regexp_replace(regexp_replace(upper(tag), '[0-9]', '9'), '[A-Z]', 'A') AS formato_tag,
3   COUNT(*) AS qtd
4 FROM workspace.bronze.om_manutencao_raw
5 WHERE tag IS NOT NULL
6 GROUP BY 1
7 ORDER BY qtd DESC;

```

	formato_tag	qtd
1	9.999.9.9999	23986
2	9.999.A.9999	897
3	9.999.9.999A	855
4	99.99.9.9999	71
5	9.999.9.9999A	55
6	9.999.9.999AA	1

6 rows • 2.982s runtime


Refreshed 12m ago

This result is stored as `_sqldf` and can be used in other Python and SQL cells.

Figura 19 – Notebook 02: Evidência de Consistência, datas fora do formato / ano 00xx, e caixa inconsistente em equipamento, nome e tag.

Evidências: Unicidade

3. UNICIDADE - duplicatas



```

1 SELECT
2   COUNT(*) AS total_linhas,
3   COUNT(DISTINCT ordem) AS ordens_distintas,
4   COUNT(*) - COUNT(DISTINCT ordem) AS ordens_duplicadas
5 FROM workspace.bronze.om_manutencao_raw;

```

	total_linhas	ordens_distintas	ordens_duplicadas
1	25872	25872	0

```

1 SELECT COUNT(*) AS grupos_de_linhas_identicas FROM (
2   SELECT ordem, equipamento, nome_equipamento, tag, tipo_manutencao, data_manutencao, data_termino, data_inicio_original, estado_om
3   FROM workspace.bronze.om_manutencao_raw
4   GROUP BY ALL
5   HAVING COUNT(*) > 1
6 );

```

	grupos_de_linhas_identicas
1	0

```


1 SELECT COUNT(*) AS equipamentos_com_mais_de_um_nome FROM (
2   SELECT upper(trim(equipamento)) AS equipamento
3   FROM workspace.bronze.om_manutencao_raw
4   GROUP BY upper(trim(equipamento))
5   HAVING COUNT(DISTINCT upper(trim(nome_equipamento))) > 1
6 );

```

	equipamentos_com_mais_de_um_nome
1	0

MVP - Data Engineering

Pipeline de Dados na Nuvem



```

1 SELECT COUNT(*) AS equipamentos_com_mais_de_uma_tag FROM (
2   SELECT upper(trim(equipamento)) AS equipamento
3   FROM workspace.bronze.om_manutencao_raw
4   GROUP BY upper(trim(equipamento))
5   HAVING COUNT(DISTINCT upper(trim(tag))) > 1
6 );
7
8

```

Table	
equipamentos_com_mais_de_uma_tag	181

Figura 20 - Notebook 02 : Evidência de Unicidade, ordens duplicadas (0) e equipamentos com mais de uma tag (181).

Evidências: Acurácia

4. ACURÁCIA - os valores fazem sentido?

Aqui convertemos as datas (já corrigindo o ano `0000xx`) só para poder comparar.

```

1 CREATE OR REPLACE TEMP VIEW vw_dados AS
2 SELECT
3   orden, tipo_manutencao, upper(estado_om) AS estado_om,
4   try_to_date(regexp_replace(data_manutencao,
5     '/00([0-9]{2})$', '/2066'), 'dd/MM/yyyy') AS data_manutencao,
6   try_to_date(regexp_replace(data_termino,
7     '/00([0-9]{2})$', '/2066'), 'dd/MM/yyyy') AS data_termino,
8   try_to_date(regexp_replace(data_inicio_original,
9     '/00([0-9]{2})$', '/2066'), 'dd/MM/yyyy') AS data_inicio_original
10  FROM workspace.bronze.om_manutencao_raw;

```

SQL query contains \$ parameter. Migrate to the parameter marker syntax, `:param`.

Parameter values:

- 1: <empty>

Learn more

```

1 SELECT 'data_inicio_original' AS coluna, MIN(data_inicio_original) AS minima, MAX(data_inicio_original) AS maxima FROM vw_dados
2 UNION ALL SELECT 'data_termino', MIN(data_termino), MAX(data_termino) FROM vw_dados
3 UNION ALL SELECT 'data_manutencao', MIN(data_manutencao), MAX(data_manutencao) FROM vw_dados;
4

```

coluna	minima	maxima
data_inicio_origi...	2026-01-01	2026-08-31
data_termino	2023-03-15	2026-09-04
data_manutencao	2022-11-28	2027-08-23

3 rows 4.385s runtime Refreshed Now

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

MVP - Data Engineering

Pipeline de Dados na Nuvem

3 minutes ago (3)

22

SQL

```

1 SELECT year(data_manutencao) AS ano, COUNT(*) AS qtd_data_manutencao
2 FROM vw_dados GROUP BY year(data_manutencao) ORDER BY ano;

```

See performance (1)

Checked for improvements

ano	qtd_data_manutencao
2021	1
2022	1
2023	3
2024	4
2025	439
2026	25410
2027	14

7 rows 3.377s runtime

Refreshed 2m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

3 minutes ago (3)

23

SQL

```

1 SELECT
2 COUNT(*) AS oms_terminadas,
3 SUM(CASE WHEN data_termino < data_inicio_original THEN 1 ELSE 0 END) AS termino_antes_do_inicio,
4 ROUND(100.0 * SUM(CASE WHEN data_termino < data_inicio_original THEN 1 ELSE 0 END) / COUNT(*), 2) AS pct
5 FROM vw_dados
6 WHERE data_termino IS NOT NULL;
7

```

See performance (1)

Checked for improvements

oms_terminadas	termino_antes_do_inicio	pct
23906	669	2.80

1 row 3.101s runtime

Refreshed 2m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.

4 minutes ago (3)

24

SQL

```

1 SELECT ordem, tipo_manutencao, data_inicio_original, data_manutencao, data_termino,
2 datediff(data_termino, data_inicio_original) AS dias
3 FROM vw_dados
4 WHERE data_termino < data_inicio_original
5 ORDER BY dias ASC
6 LIMIT 15;

```

See performance (1)


Checked for improvements

ordem	tipo_manutencao	data_inicio_original	data_manutencao	data_termino	dias
300141024	INSPEÇÃO	2026-03-13	2023-03-15	2023-03-15	-1094
200110860	CORRETIVA EMERGENCIAL	2026-04-22	2025-04-22	2025-04-22	-365
200110915	CORRETIVA PLANEJADA	2026-04-22	2025-04-25	2025-04-25	-362
300154936	PREVENTIVA	2026-08-01	2026-06-03	2026-06-03	-59
300154918	PREVENTIVA	2026-08-01	2026-06-03	2026-06-03	-59
300154935	PREVENTIVA	2026-08-01	2026-06-03	2026-06-03	-59
200117361	CORRETIVA PLANEJADA	2026-07-28	2026-06-08	2026-06-08	-50
200115278	CORRETIVA PLANEJADA	2026-06-26	2026-05-15	2026-05-15	-42
200112436	APOIO OPERACIONAL	2026-05-18	2026-04-16	2026-04-16	-32
200104308	CORRETIVA EMERGENCIAL	2026-02-04	2026-01-03	2026-01-03	-32
200111495	CORRETIVA EMERGENCIAL	2026-05-04	2026-04-03	2026-04-03	-31
200115640	CORRETIVA EMERGENCIAL	2026-07-03	2026-06-03	2026-06-03	-30
200105883	CORRETIVA EMERGENCIAL	2026-02-23	2026-01-24	2026-01-24	-30
300136716	PREVENTIVA	2026-02-02	2026-01-04	2026-01-04	-29
200110443	CORRETIVA PLANEJADA	2026-04-13	2026-03-17	2026-03-17	-27

15 rows 2.979s runtime

Refreshed 3m ago

This result is stored as `_sqlidf` and can be used in other Python and SQL cells.



```

1 SELECT
2   SUM(CASE WHEN estado_om = 'TERMINADA' AND data_termino IS NULL THEN 1 ELSE 0 END) AS terminada_sem_data,
3   SUM(CASE WHEN estado_om <> 'TERMINADA' AND data_termino IS NOT NULL THEN 1 ELSE 0 END) AS nao_terminada_com_data
4 FROM vw_dados;
5

```

	terminada_sem_data	nao_terminada_com_data
1	1	0

1 row · 3.075s runtime


This result is stored as `_sq1df` and can be used in other Python and SQL cells.

Figura 21 – Notebook 02: Evidência de Acurácia, término anterior ao início (669) e distribuição do ano de data_manutencao.

Evidências: Outliers

5. OUTLIERS - duração das manutenções

Duração = data de término - data de início original, só para OMs terminadas e sem inconsistência de datas. Usamos a regra do IQR: é outlier quem passa de $Q3 + 1,5 \times (Q3 - Q1)$.



```

1 WITH dur AS (
2   SELECT datediff(data_termino, data_inicio_original) AS dias
3   FROM vw_dados
4   WHERE estado_om = 'TERMINADA' AND data_termino >= data_inicio_original
5 ),
6 q AS (
7   SELECT percentile(dias, 0.25) AS q1, percentile(dias, 0.75) AS q3 FROM dur
8 )
9 SELECT
10  COUNT(*) AS oms_com_duracao,
11  MIN(dias) AS minimo,
12  ROUND(percentile(dias, 0.5), 1) AS mediana,
13  ROUND(AVG(dias), 2) AS media,
14  MAX(dias) AS maximo,
15  MAX(q.q3 + 1.5 * (q.q3 - q.q1)) AS limite_outlier_iqr,
16  SUM(CASE WHEN dias > q.q3 + 1.5 * (q.q3 - q.q1) THEN 1 ELSE 0 END) AS qtd_outliers
17 FROM dur CROSS JOIN q;
18

```

	oms_com_duracao	minimo	mediana	media	maximo	limite_outlier_iqr	qtd_outliers
1	23237	0	4	9.28	217	28.5	1424

Figura 22 – Notebook 02: Evidência de Outliers - estatísticas de duração (mediana, média, limite IQR e quantidade de outliers).

Análise de Dados (Etapa 4.5)

Todas as análises foram feitas em SQL sobre a camada Gold (06_analise_perguntas), com data de referência data_inicio_original. Abaixo, para cada pergunta: o resultado (evidência) e a discussão. Resultados numéricos citados foram conferidos contra o resultado do Databricks.

Pergunta 1:

Carga de trabalho: qual é a composição das OMs por grupo de manutenção (preventiva/inspeção, corretiva, projetos/melhorias, apoio) e por mês? Qual a proporção entre preventivas e corretivas?




Figura 23 – Notebook 06: Distribuição dos dados por grupo de manutenção ao longo do período analisado




Figura 24 – Notebook 06: Script do gráfico de Distribuição dos dados por grupo de manutenção ao longo do período analisado

Análise:

O volume total de Ordens de Manutenção se apresenta estável, entre ~2.700 e ~3.500 OMs por mês. Um discreto aumento é observado nos meses de janeiro e março (~3.450–3.520), o mês de janeiro pode ser justificado devido ao período de parada de produção e maior disponibilidade para atuação nas áreas

MVP - Data Engineering

Pipeline de Dados na Nuvem

produtivas. O vale em fevereiro (~2.740), pode ser justificado devido ao período de baixa na produção por motivo de feriados prolongados e menor demanda de subestações e equipamentos críticos, sendo coerente com um mês mais curto.

Composição:

- **Preventiva/Inspeção** (verde) é o maior grupo, com cerca de 1.500 a 2.000 OMs/mês, aproximadamente 50–58% do total. Atingiu o máximo em março (~1.984).
- **Corretiva** (amarelo) é o segundo maior, com ~900 a 1.300 OMs/mês. Foi mais alta em janeiro (1.300) e março (1.235) e menor em fevereiro (934) e abril (1.040), com leve recuperação depois.
- **Apoio/Administrativo** (azul) é pequeno e estável, ~180–270 OMs/mês.
- **Projetos/Melhorias** (vermelho) é o menor, mas mostra tendência de crescimento: de ~37–90 OMs no início do ano para algo em torno de 250 em julho, o maior valor da série.

A proporção corretiva/preventiva fica em torno de 35–40% do total, podendo ser aplicável um plano de ação para redução das corretivas.

Em julho houve maior crescimento de projetos/melhorias e apoio, com o total voltando perto de 3.450. É possível criar uma ação para identificar possibilidade de distribuição destas Ordens ao longo o ano.

Em agosto houve queda das ordens preventivas (~1.580) em relação a março, o que mostra eficiência na realização do plano de preventivas, sempre voltado para períodos de parada de produção.

Pergunta 2:

Equipamentos problemáticos: quais classes de equipamento concentram mais OMs corretivas (planejadas e emergenciais)?

Nota: Para esta análise foram desconsideradas ordens de Manutenção em que a identificação do equipamento era “Predial”, e ordens que não fossem do tipo corretiva e preventiva pois a proposta desta pergunta é atacar equipamentos que poderiam estar causando parada de produção ou sobrecarregando a equipe de manutenção.




Figura 25 – Notebook 06: Distribuição dos dados por tipo de equipamento e tipo de manutenção

```

1 --Opção 2
2 -- 2b) Top 10 classes de equipamento por OMs corretivas: composição das OMs
3 SELECT
4   e.classe_equipamento,
5   e.nome_classe,
6   COUNT(*) AS total_om,
7   SUM(CASE WHEN t.grupo_manutencao = 'CORRETIVA' THEN 1 ELSE 0 END) AS qtd_corretivas,
8   SUM(CASE WHEN f.tipo_manutencao = 'CORRETIVA EMERGENCIAL' THEN 1 ELSE 0 END) AS qtd_emergenciais,
9   SUM(CASE WHEN t.grupo_manutencao = 'CORRETIVA'
10      AND f.tipo_manutencao <> 'CORRETIVA EMERGENCIAL' THEN 1 ELSE 0 END) AS qtd_corretivas_comuns,
11   SUM(CASE WHEN t.grupo_manutencao <> 'CORRETIVA' THEN 1 ELSE 0 END) AS qtd_outras_om,
12   ROUND(100.0 * SUM(CASE WHEN t.grupo_manutencao = 'CORRETIVA' THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_corretiva
13 FROM workspace.gold.fato_ordem_manutencao f
14 JOIN workspace.gold.dim_equipamento e ON f.cod_equipamento = e.cod_equipamento
15 JOIN workspace.gold.dim_tipo_manutencao t ON f.tipo_manutencao = t.tipo_manutencao
16 WHERE e.classe_equipamento <> 'PREDIAL'
17 GROUP BY e.classe_equipamento, e.nome_classe
18 ORDER BY qtd_corretivas DESC
19 LIMIT 10;

```

Figura 26 – Notebook 06: Script do gráfico de Distribuição dos dados por tipo de equipamento e tipo de manutenção

Análise:

O tipo de equipamento Fancoil foi a única classe de destaque em relação às ordens corretivas emergenciais. As 359 emergenciais representam ~27% de todas as OMs deste tipo de equipamento, e somadas às 444 corretivas comuns, ~59% do total é corretivo. Mostrando que a manutenção reativa é dominante neste grupo.

As Autoclaves apresentam maior quantitativo de “outras ordens”, ou seja, ordens que não são caracterizadas como corretivas (910, ~70%). Apresentou 169 emergenciais, o segundo maior valor, mas em menor proporção (~13%). O volume alto vem de rotina planejada, o que mostra que as preventivas estão ocorrendo normalmente.

Equipamentos de Contadores de Partículas, Freezers e Ar Condicionados Split apresentaram ~70% ou mais de OMs planejadas, poucas corretivas comuns (184 a 201) e emergenciais quase nulas (0, ~3 e ~20). Demonstrando que não são equipamentos mais controlados.

As Câmaras Frias apresentam 66 emergenciais e 142 corretivas comuns contra só 111 planejadas. É a segunda classe com maior proporção reativa (~65%), e as emergenciais, em vermelho, demonstram no gráfico (~21% das OMs), o que sugere atenção e ações para redução destas ocorrências.

Os purificadores de água apresentaram apenas ordens corretivas, barra inteiramente amarela, (174 corretivas comuns + 1 emergencial) e nenhuma OM planejada. É o caso mais claro de ausência de preventiva.

Módulo de Fluxo, Lavadora e Tanque de Meios foram os perfis mais equilibrados, com corretivas comuns (107 a 120) próximas ou menores que as planejadas (131 a 232), e emergenciais baixas (~12 a 14).

Sugestões de ações:

- **Fancoil e Câmara Fria** concentram as emergenciais e têm mais OMs reativas que planejadas: prioridade para análise de causa raiz e revisão do plano preventivo.
- **Purificador de Água** devem ser verificados os planos de preventivas para esta categoria ou se há problema de cadastro.
- Fancoil e Autoclave somam ~528 das ~657 emergenciais do Top 10 (~80%). Construir planos de ação voltados para essas duas classes poderá reduzir a maior parte das paradas emergenciais.

Pergunta 3:

Conclusão e backlog: qual a taxa de conclusão das OMs por grupo e por tipo de manutenção? Onde se concentram as OMs suspensas e não iniciadas?




Figura 27 - Notebook 06: Gráfico de taxa de conclusão das ordens de manutenção por tipo

```

1 -- 3a) Estado das OMs por grupo, em quantidade e percentual
2 SELECT
3   t.grupo_manutencao,
4   COUNT(*)
5   SUM(CASE WHEN f.estado_om = 'TERMINADA' THEN 1 ELSE 0 END) AS total_om,
6   SUM(CASE WHEN f.estado_om = 'INICIADA' THEN 1 ELSE 0 END) AS terminadas,
7   SUM(CASE WHEN f.estado_om = 'NÃO INICIADA' THEN 1 ELSE 0 END) AS iniciadas,
8   SUM(CASE WHEN f.estado_om = 'SUSPENSÃO' THEN 1 ELSE 0 END) AS nao_iniciadas,
9   SUM(CASE WHEN f.estado_om = 'SUSPENSÃO' THEN 1 ELSE 0 END) AS suspensas,
10  ROUND(100 * SUM(CASE WHEN f.estado_om = 'TERMINADA' THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_terminadas
11 FROM workspace.gold.fato_ordem_manutencao f
12 JOIN workspace.gold.dim_tipo_manutencao t ON f.tipo_manutencao = t.tipo_manutencao
13 GROUP BY t.grupo_manutencao
14 ORDER BY pct_terminadas;

```

Figura 28 – Notebook 06: Script do gráfico de taxa de conclusão das ordens de manutenção

Análise:

Os dados mostram que em geral a taxa de execução é alta em todos os grupos, mas os grupos reativos e de projetos concentram os problemas de andamento. O que não foi concluído está sobretudo em suspensas e não iniciadas.

- **Preventiva/Inspeção** (98,4%): praticamente tudo concluído. Restam 201 não iniciadas (~1,5%), 12 iniciadas e nenhuma suspensa. É o grupo com melhor aderência ao plano.
- **Apoio/Administrativo** (97,3%): resíduo muito pequeno (16 iniciadas, 16 não iniciadas, 15 suspensas).
- **Corretiva** (84,6%): tem a maior faixa vermelha entre os grupos grandes. As 913 suspensas representam ~9,6% das OMs, e há mais 348 não iniciadas (~3,7%) e 201 em andamento.
- **Projetos/Melhorias** (76,2%): o menor percentual de conclusão. Tem ~10% suspensas (103) e ~10% não iniciadas (100), além de 40 iniciadas (~4%).

Sugestão de ações:

- As **913 suspensas da Corretiva** são o maior passivo em números absolutos (mais de 8 vezes as suspensas de Projetos). Vale investigar os motivos (falta de peça, aguardando aprovação, parada de equipamento indisponível) e o tempo de suspensão.
- **Projetos/Melhorias** tem o pior desempenho relativo, mas é um grupo pequeno (1.019 OMs). Suspensão e não início comuns são esperados em projetos, mas ~20% sem andamento merece revisão de priorização ou análise de real necessidade destas ordens.
- As **201 não iniciadas da Preventiva** são o único desvio do grupo. Deve-se avaliar se são OMs antigas, vencidas ou recém-geradas para identificar possíveis falhas nos planos de preventivas.

Pergunta 4:

Tempo de execução: quanto tempo (mediana e média, em dias) as manutenções levam, por grupo e por tipo?




Figura 29 – Notebook 06: Gráfico de análise de tempo de execução de ordens



Figura 30 – Notebook 06: Script do Gráfico de análise de tempo de execução de ordens

Análise:

Foi possível identificar em todos os grupos que a média é maior que a mediana, o que indica distribuições assimétricas à direita: a maioria das OMs fecha rápido, mas um grupo menor de OMs longas puxa a média para cima. Sendo assim mais recomendável utilizar a mediana como medida de tempo em dashboards e análises futuras.

Nota: as médias consideram apenas ordens em que foi possível calcular a duração, ou seja, ordens que já foram terminadas e que possuem datas de término.

MVP - Data Engineering

Pipeline de Dados na Nuvem

Análise por grupo:

- **Corretiva:** o maior contraste relativo. A mediana é de só 2 dias, mas a média é de 9,5 (~4,7 vezes maior). A maioria dos reparos é rápida, mas há casos muito longos, com máximo de 217 dias, o maior de todos os grupos.
- **Projetos/Melhorias:** tem a maior média (11,8) e mediana de 5 dias. Duração alta em geral, coerente com a natureza dessas OMs, e com cauda longa (máximo de 130).
- **Preventiva/Inspeção:** a maior mediana (6) e média de 9,4, a mais próxima da mediana entre os grupos grandes. As durações são maiores, porém mais regulares, o que é esperado em atividades planejadas. O máximo é 194 dias.
- **Apoio/Administrativo:** as menores durações (mediana 2, média 5,6), com poucos casos extremos, embora o máximo chegue a 161 dias.

Sugestão de ações:

Avaliar as ordens suspensas, pois a cauda longa nas Corretivas, com mediana de 2 dias, uma média de 9,5 e máximo de 217 dias, são acima de 30 dias. São as que mais pesam no indicador de tempo de reparo, indicando que a falta de material para execução pode estar atrelada diretamente ao aumento destes tempos.

Avaliar as ordens com tempos acima de 100 dias em todos os grupos (inclusive Apoio, com 161 e Preventiva, com 194): podem ser OMs esquecidas em aberto, encerradas tardiamente ou erro de data.

Pergunta 5:

Evolução mensal: como evoluíram, de janeiro a agosto, o volume de OMs, a taxa de conclusão e as corretivas emergenciais?




Tabela 31 – Notebook 06: Gráfico de evolução mensal das ordens terminadas

```

1 -- Sa) Volume e taxa de conclusão por mês
2 SELECT
3   d.ano_mes,
4   COUNT(*) AS total_om,
5   SUM(CASE WHEN f.estado_om = 'TERMINADA' THEN 1 ELSE 0 END) AS terminadas,
6   ROUND(100.0 * SUM(CASE WHEN f.estado_om = 'TERMINADA' THEN 1 ELSE 0 END) / COUNT(*), 1) AS pct_terminadas
7 FROM workspace.gold.fato_ordem_manutencao f
8 JOIN workspace.gold.dim_data d ON f.data_inicio_original = d.data
9 GROUP BY d.ano_mes
10 ORDER BY d.ano_mes;
11
> See performance (1)

```

Tabela 32 – Notebook 06: Script para gráfico de evolução mensal das ordens terminadas

Análise:

O volume mensal de ordens abertas é estável. As barras ficam entre 2,74 mil (fevereiro, o mês mais baixo) e 3,52 mil OMs (março, o mais alto), somando as 25.872 ordens do período. Não há tendência de alta nem de queda, no geral a demanda de manutenção é regular, com variação de cerca de 20% entre o menor e o maior mês.

O ponto de atenção é que a taxa de conclusão cai de forma progressiva, mostrando:

Período Taxa de conclusão

Jan a Mai entre 97,1% e 94,9%

Junho 92,2%

Julho 89,4%

Agosto 79,1%

A queda é leve até maio (cerca de 2 pontos), acelera em junho e julho e é forte em agosto (10 pontos a menos que em julho). Em agosto, cerca de 1 em cada 5 OMs ainda não foi terminada.

É importante destacar que a queda não vem do volume de ordens abertas, pois este número se mantém na mesma faixa. Agosto (3,24 mil) tem quase o mesmo número de OMs que janeiro (3,46 mil), mas 18 pontos percentuais a menos de conclusão. Fevereiro teve o menor volume e ainda assim uma taxa alta (96,1%). Isso demonstra o impacto no tempo de fechamento das ordens, dado que a base de dados foi extraída em agosto e possíveis problemas para na capacidade de fechar as ordens.

Deve ser feita uma análise focada no acúmulo real de pendências (backlog). A queda já aparece em junho, quando a maioria das OMs deveria estar fechada. Isso sugere um acúmulo de ordens abertas que merece investigação (equipe, peças, priorização das emergenciais).

É recomendado acompanhar as OMs abertas há mais de 30 dias.

Considerações Finais

Este trabalho construiu, na plataforma Databricks, um pipeline de dados em três camadas (Bronze, Silver e Gold) a partir de 25.872 ordens de manutenção (OMs) de janeiro a agosto de 2026. Nenhuma linha foi perdida ao longo do processo: o volume se manteve igual em todas as camadas. Os problemas de qualidade encontrados, como o ano digitado incorretamente e variações de maiúsculas e minúsculas. Foi verificado com as equipes que os dados com datas de término anteriores ao início se trata de irregularidades no fluxo do processo e foram sinalizadas ações para evitar estes erros. Com isso, as análises puderam usar dados confiáveis sem apagar informação da fonte.

A análise mostrou que a manutenção é dominada por atividades preventivas e de inspeção (52,7% das OMs), seguidas pelas corretivas (36,7%). A taxa geral de conclusão foi de 92,4%, com diferenças importantes entre os grupos: alta nas preventivas (98,4%) e mais baixa nas corretivas (84,6%) e nos projetos e melhorias (76,2%). Entre as corretivas, a classe predial foi desconsiderada na análise de equipamentos, mas concentra a maior parte das ordens (41,3%), enquanto, entre os demais equipamentos, a classe FAC teve o maior número de ocorrências. Para isto, recomendou-se para as equipes de manutenção identificar melhor a tipologia “PREDIAL” para melhoria das análises futuras.

O resultado que mais merece atenção é a evolução mensal: o volume de OMs foi estável (2,7 a 3,5 mil por mês), mas a taxa de conclusão caiu de 97,1% em janeiro para 79,1% em agosto. Parte dessa queda pode ser efeito de OMs recentes ainda em andamento na data da extração e do tempo de execução que as mesmas demandam (maior que 30 dias) mas a redução já visível em junho e julho indica possível acúmulo de pendências. Recomenda-se acompanhar mensalmente as OMs abertas há mais tempo e investigar a causa da queda, como equipe, peças ou priorização.

Como limitações, o trabalho usa uma única extração, sem data de encerramento planejada. Como próximos passos, o pipeline pode ser agendado para rodar de forma automática e incluir novas cargas mensais.

Autoavaliação

Este trabalho foi meu primeiro contato com ferramentas de nuvem para dados, nunca usei a ferramenta Databricks e conheci o GitHub a partir desta Pós Graduação, pois minha formação não é da área de dados, sou da área da Saúde. A maior dificuldade inicial foi o vocabulário técnico — termos usados dentro das ferramentas e mesmo nos materiais de estudo precisaram ser estudados um a um antes de eu conseguir aplicá-los com segurança. Também tive dificuldade em entender a diferença entre o workspace (onde ficam os notebooks) e o catálogo (onde ficam as tabelas), já que os dois aparecem em telas parecidas no Databricks.

No processo de construção do pipeline, o maior aprendizado foi perceber que qualidade de dados não significa apagar o que está errado, mas sim entender por que está errado e decidir, com critério e conhecimento dos dados, entre corrigir ou sinalizar. Diagnosticar os problemas do arquivo de manutenção (datas trocadas, texto em caixa alta e baixa misturado, um ano digitado errado) e depois tratá-los na camada Silver me deu uma noção prática de como dados brutos de um sistema real (no meu caso, dados reais do meu local de trabalho) raramente chegam prontos para análise.

Também enfrentei dificuldades técnicas ao longo do caminho, como ajustar consultas SQL que não rodavam como esperado, pois o SQL é muito novo para mim e foi meu primeiro contato nesta sprint.



MVP - Data Engineering

Pipeline de Dados na Nuvem

Por fim, o exercício de transformar uma planilha de ordens de manutenção em um modelo dimensional e usá-lo para responder perguntas de negócio mudou minha forma de olhar para dados operacionais. Percebi que decisões de modelagem têm impacto direto na qualidade das análises. Considero que este projeto me deu uma base sólida sobre engenharia de dados na prática, algo que pretendo aplicar em meu ambiente de trabalho.

Me ajudou muito utilizar dados de processos que eu conheço bem, permitindo a definição de critérios e premissas no momento das análises e compreendendo melhor os detalhes da base. Além disso, construir o pipeline me fez sentir muito mais organizada e mais segura na hora de mostrar os dados. Esta prática certamente contribuiu com a evolução do meu olhar para com o meu trabalho.